

**Pengembangan dan Evaluasi Model Hybrid Isolation Forest–Bayesian
Network untuk Deteksi Risiko Multi-Domain pada Rantai Pasok
Pertanian**

PROPOSAL PENELITIAN

**Diajukan untuk Memenuhi Salah Satu Syarat kelulusan Strata 1
di Program Studi Sistem Informasi Universitas Widyatama**

Oleh

NAMA : Muhamad Surya Al Ghifari

NPM : 41121100003



**PROGRAM STUDI SISTEM INFORMASI
FAKULTAS TEKNIK UNIVERSITAS WIDYATAMA
BANDUNG**

2026

DAFTAR ISI

DAFTAR ISI.....	ii
DAFTAR TABEL.....	iv
DAFTAR GAMBAR.....	v
BAB I PENDAHULUAN.....	1
1.1. Latar Belakang Masalah.....	1
1.2. Identifikasi dan Rumusan Masalah	3
1.3. Batasan Masalah.....	4
1.4. Tujuan Penelitian	4
1.5. Manfaat Penelitian	5
BAB II KAJIAN PUSTAKA.....	6
2.1. Tinjauan Teori.....	6
2.1.1. <i>Anomaly Detection</i> Pada Sistem Rantai Pasok	6
2.1.2. <i>Isolation Forest</i> Dalam Deteksi Anomali	7
2.1.3. <i>Bayesian Network</i> Untuk Pemodelan Risiko	9
2.1.4. Model <i>Hybrid</i> Dalam <i>Machine Learning</i>	11
2.1.5. Deteksi Risiko <i>Multi-Domain</i> Pada Sektor Pertanian.....	13
2.1.6. Sistem Peringatan Dini Berbasis <i>AI</i>	15
2.1.7. Ringkasan dan Posisi Penelitian	18
2.1.8. Kerangka Pemikiran	21
2.2. Tinjauan Pustaka	22
2.2.1. Konsep Risiko dan Ketidakpastian	22
2.2.2. Rantai Pasok Pertanian dan Karakteristik Risikonya	23
2.2.3. Teori <i>Anomaly Detection</i>	25
2.2.4. Teori <i>Isolation Forest</i>	26
2.2.5. Teori <i>Bayesian Network</i>	27
2.2.6. <i>Naive Bayesian Network (Label Features)</i>	28
2.2.7. Model <i>Hybrid</i> Dalam Sistem Cerdas	30
2.2.8. Integrasi Skor dan Strategi Agregasi	31
2.2.9. Evaluasi Model Klasifikasi dan Deteksi Anomali	31
2.2.10. Penanganan <i>Data Imbalance</i>	33
BAB III METODOLOGI.....	35
3.1. Jenis Penelitian.....	35

3.2.	Metode Pengembangan Model.....	36
3.3.	Objek Penelitian	37
3.3.1.	Domain Risiko Penelitian	38
3.3.2.	Entitas, Variabel, Satuan, dan Sumber Data	43
3.3.3.	Unit Analisis Penelitian	46
3.4.	Teknik Pengumpulan Data	46
3.5.	Teknik Analisis Data	47
3.5.1.	Pembentukan Label Risiko	47
3.5.2.	<i>Preprocessing</i> dan <i>Feature Engineering</i>	49
3.5.3.	Pengembangan Model <i>Isolation Forest</i>	52
3.5.4.	Pengembangan Model <i>Bayesian Network</i>	54
3.5.5.	Pengembangan Model <i>Hybrid Isolation Forest–Bayesian Network</i>	56
3.5.6.	Mekanisme <i>Threshold</i> dan Keputusan Deteksi	59
3.5.7.	Evaluasi Model	62
3.5.8.	<i>Kalibrasi, Uncertainty, dan Explainability</i> Model	64
3.6.	Alur Penelitian	67
3.7.	Jadwal Penelitian.....	70
DAFTAR PUSTAKA		71

DAFTAR TABEL

Tabel 2.1 Ringkasan Penelitian Terdahulu	19
Tabel 2.1 (lanjutan).....	20
Tabel 3.1 Variabel, Satuan, dan Sumber Data per Domain	43
Tabel 3.1 (lanjutan).....	44
Tabel 3.1 (lanjutan).....	45
Tabel 3.2 Strategi <i>Temporal Alignment</i> per Domain.....	51
Tabel 3.3 Jadwal Penelitian	70

DAFTAR GAMBAR

Gambar 2.1 Kerangka Pemikiran.....	22
Gambar 3.1 <i>Pipeline</i> Pengembangan Model	36
Gambar 3.2 Alur Pengembangan Model Hybrid	57
Gambar 3.3 Alur Penelitian	67

BAB I

PENDAHULUAN

1.1. Latar Belakang Masalah

Rantai pasok pertanian menghadapi tekanan yang semakin kompleks akibat keterkaitan antara faktor ekonomi, lingkungan, dan operasional yang terus berkembang. Gangguan pada satu titik dalam sistem, seperti guncangan harga komoditas, anomali cuaca, atau hambatan distribusi, dapat merambat dan memperburuk kondisi pada titik lainnya secara bersamaan [1], [2]. Bukti empiris menunjukkan bahwa variasi cuaca mampu menjelaskan lebih dari separuh variasi hasil pertanian dan berdampak lanjutan pada pendapatan petani serta stabilitas kredit [3]. Di sisi lain, dinamika harga komoditas juga dipengaruhi secara simultan oleh faktor energi, iklim, dan interaksi pasar. Kondisi tersebut menunjukkan bahwa risiko pada rantai pasok pertanian tidak dapat dipahami hanya dari satu domain, melainkan terbentuk dari interaksi beberapa lapisan risiko dengan karakteristik yang berbeda. Oleh karena itu, diperlukan pendekatan deteksi yang mampu memantau beberapa domain secara bersamaan sebagai dasar sistem peringatan dini yang lebih terstruktur [1]–[3].

Berbagai penelitian mengenai deteksi anomali dan pemodelan risiko pada sektor pertanian menunjukkan potensi yang cukup besar, tetapi sebagian besar masih dilakukan secara parsial, misalnya hanya berfokus pada domain harga, cuaca, atau organisme pengganggu tanaman [4]–[7], [3], [8]. Selain itu, pendekatan yang digunakan umumnya masih bertumpu pada model tunggal yang memiliki keterbatasan masing-masing. Isolation Forest unggul dalam mendeteksi penyimpangan secara *unsupervised* dan efisien pada data multivariat, tetapi terbatas dalam memberikan interpretasi probabilistik [10]–[12]. Sebaliknya, Bayesian Network kuat dalam pemodelan risiko probabilistik dan inferensi di bawah ketidakpastian, tetapi menghadapi tantangan pada data kontinu berskala besar, pembentukan struktur model, dan heterogenitas data [9], [12], [13]. Perbedaan karakteristik tersebut menunjukkan bahwa kedua metode memiliki potensi yang saling melengkapi. Isolation Forest dapat menangkap sinyal penyimpangan tanpa bergantung pada label, sedangkan Bayesian Network dapat memperkuat keputusan deteksi melalui inferensi probabilistik berbasis label operasional [14], [15]. Meskipun demikian, integrasi eksplisit antara kedua metode tersebut dalam satu kerangka deteksi risiko multi-domain pada rantai pasok pertanian masih relatif terbatas.

Kebutuhan akan pendekatan yang menghubungkan deteksi anomali dengan inferensi probabilistik dalam satu kerangka multi-domain masih menjadi celah penelitian yang belum banyak dieksplorasi. Model *hybrid* yang mengintegrasikan Isolation Forest dan Bayesian Network berpotensi memanfaatkan keunggulan kedua metode secara bersama-sama, sehingga hasil deteksi tidak hanya mampu mengidentifikasi penyimpangan, tetapi juga memberikan dasar penalaran risiko yang lebih terstruktur [14]–[16]. Di sisi lain, pendekatan per-domain tetap diperlukan agar perbedaan karakteristik data pada setiap domain dapat ditangani secara lebih sesuai, baik dalam pembentukan fitur, pembentukan label, maupun mekanisme deteksi. Dengan demikian, integrasi model *hybrid* dan pemodelan per-domain merupakan dua kebutuhan metodologis yang saling berkaitan dalam pengembangan sistem deteksi risiko multi-domain.

Berdasarkan keterbatasan pendekatan yang ada dan kebutuhan akan deteksi risiko *multi-domain* yang lebih terstruktur, penelitian ini mengembangkan dan mengevaluasi model *hybrid* Isolation Forest–Bayesian Network untuk deteksi risiko *multi-domain* pada rantai pasok pertanian. Model dikembangkan secara *per-domain* untuk menangani perbedaan karakteristik data pada enam domain risiko, yaitu harga, cuaca, organisme pengganggu tanaman (OPT), distribusi, tindakan pengelolaan, dan produksi. Pemodelan dilakukan dengan resolusi mingguan per kecamatan di Kabupaten Sumedang, menggunakan data historis periode 2022–2024, agar pola musiman dan tren multi-tahun pada masing-masing domain risiko dapat direpresentasikan secara memadai. Evaluasi dilakukan dengan membandingkan performa model *Isolation Forest*, *Bayesian Network*, dan model *hybrid* dalam menghasilkan probabilitas risiko dan keputusan deteksi, sebagai dasar pengembangan sistem peringatan dini pada rantai pasok pertanian. Dengan demikian, penelitian ini diharapkan memberikan kontribusi metodologis terhadap pengembangan pendekatan deteksi risiko yang lebih terstruktur dan relevan untuk sektor pertanian.

1.2. Identifikasi dan Rumusan Masalah

a) Identifikasi Masalah

Berdasarkan latar belakang yang telah diuraikan, dapat diidentifikasi beberapa masalah sebagai berikut:

- (1) Risiko pada rantai pasok pertanian bersifat multi-domain dan memiliki karakteristik yang berbeda pada setiap domain, sehingga tidak mudah dideteksi dengan pendekatan tunggal.
- (2) Pendekatan deteksi risiko pada sektor pertanian masih cenderung dilakukan secara parsial, misalnya hanya pada domain harga, cuaca, atau organisme pengganggu tanaman.
- (3) Isolation Forest dan Bayesian Network memiliki keunggulan yang berbeda dalam deteksi risiko, namun belum banyak diintegrasikan secara eksplisit dalam satu model untuk deteksi risiko multi-domain pada rantai pasok pertanian.
- (4) Diperlukan evaluasi untuk membandingkan performa model tunggal dan model hybrid dalam mendeteksi risiko pada data penelitian.

b) Rumusan Masalah

Berdasarkan identifikasi masalah tersebut, maka rumusan masalah dalam penelitian ini adalah sebagai berikut:

- (1) Bagaimana mengembangkan model *hybrid Isolation Forest-Bayesian Network* untuk deteksi risiko *multi-domain* pada rantai pasok pertanian?
- (2) Bagaimana performa *Isolation Forest*, *Bayesian Network*, dan model *hybrid Isolation Forest-Bayesian Network* dalam mendeteksi risiko pada masing-masing domain dalam rantai pasok pertanian?
- (3) Bagaimana hasil perbandingan performa antara *Isolation Forest*, *Bayesian Network*, dan model *hybrid Isolation Forest-Bayesian Network* dalam menghasilkan skor risiko dan keputusan deteksi pada data penelitian?

1.3. Batasan Masalah

Batasan masalah dalam penelitian ini ditetapkan agar ruang lingkup penelitian tetap terarah dan sesuai dengan tujuan yang telah ditetapkan. Batasan-batasan masalah dalam penelitian ini adalah sebagai berikut:

- a) Penelitian difokuskan pada pengembangan dan evaluasi model *hybrid Isolation Forest–Bayesian Network* untuk deteksi risiko *multi-domain* pada rantai pasok pertanian. Keluaran model berupa probabilitas risiko, keputusan deteksi anomali, dan tingkat keparahan per domain dirancang agar dapat diintegrasikan ke dalam sistem peringatan dini, namun implementasi sistem secara operasional berada di luar cakupan penelitian ini.
- b) Data yang digunakan merupakan data historis periode 2022–2024 pada wilayah Kabupaten Sumedang.
- c) Domain risiko yang dianalisis mencakup enam domain, yaitu harga, cuaca, organisme pengganggu tanaman (OPT), distribusi, tindakan pengelolaan, dan produksi.
- d) Evaluasi penelitian difokuskan pada keluaran model berupa skor risiko dan keputusan deteksi terhadap label operasional yang telah dibentuk, sehingga tidak mencakup evaluasi terhadap alert operasional secara menyeluruh.

1.4. Tujuan Penelitian

Berdasarkan rumusan masalah yang telah ditetapkan, maka tujuan penelitian ini adalah sebagai berikut:

- a) Mengembangkan model *hybrid Isolation Forest–Bayesian Network* untuk deteksi risiko *multi-domain* pada rantai pasok pertanian.
- b) Mengevaluasi performa *Isolation Forest*, *Bayesian Network*, dan model *hybrid Isolation Forest–Bayesian Network* dalam mendeteksi risiko pada masing-masing domain dalam rantai pasok pertanian.
- c) Menganalisis hasil perbandingan performa antara *Isolation Forest*, *Bayesian Network*, dan model *hybrid Isolation Forest–Bayesian Network* dalam menghasilkan skor risiko dan keputusan deteksi pada data penelitian.

1.5. Manfaat Penelitian

a) Manfaat Teoritis

- (1) Memberikan kontribusi pada pengembangan kajian mengenai integrasi metode *anomaly detection* dan *probabilistic reasoning* dalam deteksi risiko *multi-domain* pada rantai pasok pertanian.
- (2) Menambah referensi akademik mengenai penerapan model *hybrid Isolation Forest–Bayesian Network* dalam deteksi risiko berbasis data.
- (3) Memperkaya pemahaman tentang penggunaan pendekatan *per-domain* dalam pemodelan risiko pertanian yang memiliki karakteristik data dan distribusi yang berbeda.

b) Manfaat Praktis

- (1) Memberikan dasar pengembangan sistem deteksi risiko yang lebih terstruktur untuk memantau berbagai domain risiko pada rantai pasok pertanian.
- (2) Menghasilkan keluaran model berupa probabilitas risiko, keputusan deteksi anomali, dan tingkat keparahan (*severity*) per domain yang dapat dimanfaatkan sebagai dasar pengembangan sistem peringatan dini pada rantai pasok pertanian.
- (3) Menjadi referensi bagi peneliti atau pengembang sistem yang ingin menerapkan pendekatan *hybrid* pada data risiko pertanian atau data *multi-domain* sejenis.

BAB II

KAJIAN PUSTAKA

2.1. Tinjauan Teori

2.1.1. *Anomaly Detection* Pada Sistem Rantai Pasok

Penelitian mengenai *anomaly detection* pada sistem rantai pasok menunjukkan bahwa anomali tidak hanya muncul pada aktivitas distribusi barang, tetapi juga pada struktur hubungan antarentitas, pergerakan logistik, dinamika harga komoditas, hingga proses produksi pertanian. Seiring dengan semakin beragamnya bentuk data yang digunakan, mulai dari graf jaringan, data sensor *real-time*, deret waktu harga, hingga data multimodal pertanian, pendekatan deteksi anomali yang diterapkan juga berkembang menjadi semakin kompleks. Hal ini menunjukkan bahwa deteksi anomali merupakan bagian penting dalam mengidentifikasi gangguan, penyimpangan, dan risiko yang dapat memengaruhi kinerja rantai pasok secara keseluruhan [4]–[7].

Pada struktur jaringan rantai pasok, anomali dapat dipahami sebagai penyimpangan hubungan antar-*node* dalam jaringan pengadaan. Pendekatan berbasis graf melalui *Graph Balancing Theory*, *Laplacian flow*, dan *Sheaf theory* digunakan untuk mengidentifikasi entitas yang menunjukkan inkonsistensi struktural dalam jaringan *supply chain* [4]. Temuan tersebut menunjukkan bahwa anomali pada rantai pasok tidak selalu termanifestasi sebagai gangguan operasional yang tampak secara langsung, tetapi juga dapat berbentuk distorsi informasi serta ketidakwajaran pola relasi antarpelaku dalam jaringan [4].

Pada distribusi logistik, anomali umumnya muncul pada aliran data sensor yang dipantau secara *real-time*, seperti suhu, kelembapan, oksigen, karbon dioksida, dan tekanan pada logistik rantai dingin [5]. Untuk mendeteksi penyimpangan tersebut, digunakan *improved Isolation Forest* yang terbukti memberikan kinerja lebih baik dibandingkan *Support Vector Machine (SVM)*, *Local Outlier Factor (LOF)*, dan *Isolation Forest* standar [5]. Temuan ini mengindikasikan bahwa metode deteksi anomali pada distribusi logistik perlu mampu menangani data *streaming* multivariat dengan ketergantungan temporal yang kuat [5].

Selain pada jaringan dan distribusi, deteksi anomali juga diterapkan pada harga komoditas dan produksi pertanian. Pada harga komoditas, anomali dideteksi melalui kombinasi *Transformer* dan *attention-boosted LSTM-VAE* untuk mengenali perubahan harga yang tidak wajar pada deret waktu harian [6]. Sementara itu, pada produksi pertanian, anomali muncul dalam bentuk gangguan kesehatan tanaman, seperti serangan hama, penyakit, defisiensi nutrisi, dan stres lingkungan. Untuk menangani kondisi tersebut, digunakan pendekatan *deep learning* multimodal yang memadukan *multi-modal fusion*, *Graph Neural Network (GNN)*, *Transformer*, dan *Variational Autoencoder (VAE)* agar berbagai sumber data dapat dianalisis secara terpadu [7]. Kedua penelitian tersebut menunjukkan bahwa data harga dan produksi menuntut metode yang lebih kompleks karena pola yang diamati bersifat dinamis, heterogen, serta memiliki keterkaitan temporal dan spasial [6], [7].

Berdasarkan penelitian-penelitian tersebut, dapat disimpulkan bahwa *anomaly detection* pada sistem rantai pasok telah diterapkan pada berbagai aspek, mulai dari struktur jaringan *supply chain*, distribusi logistik, harga komoditas, hingga produksi pertanian [4]–[7]. Setiap penelitian menggunakan pendekatan yang berbeda sesuai dengan karakteristik data dan objek anomali yang dianalisis. Namun, sebagian besar penelitian masih berfokus pada satu domain tertentu, sehingga hasil deteksi cenderung bersifat parsial dan belum sepenuhnya menggambarkan keterkaitan antarsumber risiko dalam rantai pasok pertanian secara menyeluruh. Dengan demikian, penelitian mengenai *anomaly detection* pada sistem rantai pasok masih menunjukkan kebutuhan akan pengembangan pendekatan yang lebih terintegrasi [4]–[7].

2.1.2. *Isolation Forest* Dalam Deteksi Anomali

Isolation Forest merupakan salah satu metode *anomaly detection* berbasis *isolation* yang dikembangkan dengan asumsi bahwa data anomali cenderung lebih mudah dipisahkan dibandingkan data normal. Berbeda dengan pendekatan yang bergantung pada estimasi densitas atau perhitungan jarak antar titik data, *Isolation Forest* membangun sekumpulan pohon acak untuk mengisolasi observasi melalui proses partisi berulang. Semakin pendek jalur isolasi suatu data, semakin besar kemungkinan data tersebut merupakan anomali. Karakteristik ini menjadikan *Isolation Forest* banyak digunakan dalam penelitian deteksi anomali karena mampu

bekerja tanpa data berlabel, relatif efisien secara komputasi, dan dapat diterapkan pada berbagai bentuk data multivariat [17]–[20].

Dalam penelitian terdahulu, *Isolation Forest* telah diterapkan pada berbagai konteks deteksi anomali, terutama pada sistem *monitoring* dan data operasional multivariat. Pada konteks *software-defined networking* (SDN), metode ini digunakan untuk mendeteksi anomali lalu lintas jaringan dan dihubungkan dengan *decision engine*, *alert system*, serta pembaruan kebijakan secara adaptif [17]. Pada penelitian lain, *Isolation Forest* diterapkan untuk mendeteksi aplikasi *mobile* yang mencurigakan berdasarkan pola *permission request* dalam bentuk fitur biner berdimensi tinggi [18]. Selain itu, dalam konteks *process quality control*, *Isolation Forest* juga digunakan sebagai *novelty detector* untuk memantau proses multivariat non-normal dan dibandingkan dengan pendekatan statistik klasik seperti Hotelling's T^2 [20]. Ragam penerapan tersebut menunjukkan bahwa *Isolation Forest* tidak terbatas pada satu domain tertentu, tetapi cukup fleksibel untuk digunakan pada data yang memiliki struktur, distribusi, dan tujuan pemantauan yang berbeda.

Salah satu alasan utama banyaknya penggunaan *Isolation Forest* adalah kemampuannya menangani data multivariat dan berdimensi tinggi secara relatif efisien. Pada deteksi aplikasi *mobile*, *Isolation Forest* dinilai sesuai untuk data *permission request* yang terdiri atas banyak fitur biner dan bersifat tidak seimbang, terutama setelah dilakukan *parameter tuning* yang tepat [18]. Penelitian tersebut menunjukkan bahwa pengaturan parameter yang baik mampu menurunkan *false positive* secara signifikan serta meningkatkan *precision*, sehingga memperlihatkan bahwa keandalan *Isolation Forest* tidak hanya terletak pada algoritmanya, tetapi juga pada konfigurasi model yang digunakan [18]. Di sisi lain, penelitian pada *process quality control* menunjukkan bahwa *Isolation Forest* memiliki keunggulan pada data multivariat *non-Gaussian*, karena tidak bergantung pada asumsi distribusi tertentu sebagaimana pendekatan berbasis kovarians [20]. Dengan demikian, *Isolation Forest* dapat dipandang sebagai metode yang cukup kuat untuk mendeteksi penyimpangan pada data kompleks yang sulit ditangani oleh metode statistik konvensional.

Meskipun memiliki keunggulan tersebut, *Isolation Forest* memiliki dua keterbatasan penting. Pertama, sensitivitas terhadap *contamination rate* yang berpengaruh langsung terhadap ambang keputusan dan jumlah anomali yang dihasilkan [17],[18]. Pada konteks SDN, peningkatan *contamination* berkorelasi dengan bertambahnya *alert* dan perubahan kebijakan, sehingga muncul *trade-off* antara sensitivitas deteksi dan stabilitas operasional [17]. Pada deteksi aplikasi *mobile*, *contamination* juga menjadi *hyperparameter* penentu keseimbangan antara peningkatan deteksi dan risiko *false positive* [18]. Kedua, keterbatasan interpretabilitas. Keluaran *Isolation Forest* berupa skor anomali tidak secara langsung menjelaskan mengapa suatu observasi dianggap abnormal. Keterbatasan ini mendorong pengembangan seperti CADI yang membedakan *local* dan *global anomaly* berdasarkan struktur *inlier* [19]. Selain itu, *Isolation Forest* memiliki sensitivitas rendah terhadap perubahan halus seperti *small mean shift* [20]. Temuan-temuan ini menunjukkan bahwa kekuatan *Isolation Forest* dalam efisiensi dan fleksibilitas belum sepenuhnya diikuti oleh kemampuan penjelasan dan pemodelan hubungan antar variabel.

2.1.3. *Bayesian Network* Untuk Pemodelan Risiko

Bayesian Network merupakan salah satu pendekatan probabilistik yang banyak digunakan dalam pemodelan risiko karena mampu merepresentasikan hubungan ketergantungan antar variabel dalam bentuk *directed acyclic graph* (DAG). Melalui struktur tersebut, *Bayesian Network* tidak hanya digunakan untuk menghitung probabilitas suatu kejadian, tetapi juga untuk melakukan *probabilistic reasoning*, *diagnostic inference*, *predictive inference*, dan analisis ketidakpastian secara lebih terstruktur. Karakteristik ini menjadikan *Bayesian Network* relevan dalam berbagai kebutuhan pengambilan keputusan di bawah kondisi tidak pasti, terutama ketika hubungan antar faktor risiko perlu dipahami secara eksplisit [9]–[12].

Dalam penelitian terdahulu, *Bayesian Network* telah diterapkan pada berbagai bidang pemodelan risiko, mulai dari lingkungan industri, prediksi risiko klinis, hingga sistem *monitoring* pada infrastruktur [9], [10], [12]. Pada skala industri besar, *Bayesian Network* digunakan untuk memodelkan dependensi antar variabel risiko, menangani data yang tidak lengkap, serta mendukung inferensi diagnostik, prognostik, dan *counterfactual reasoning* dalam pengambilan keputusan operasional

[9]. Sementara itu, pada *structural health monitoring*, *Bayesian Network* dimanfaatkan untuk mengintegrasikan data multi-sensor, memperbarui keyakinan ketika data baru masuk, serta mendukung *early warning* dan strategi pemeliharaan [12]. Temuan-temuan ini menunjukkan bahwa kekuatan utama *Bayesian Network* terletak pada kemampuannya menghubungkan berbagai sumber informasi dalam satu kerangka probabilistik yang koheren [9], [12].

Selain digunakan sebagai alat *probabilistic reasoning*, pendekatan Bayesian juga berkembang dalam bentuk yang lebih sederhana, yaitu *Naive Bayes*, untuk keperluan klasifikasi risiko. Pada penelitian di bidang penilaian risiko kredit, *Naive Bayes* digunakan untuk mengklasifikasikan kelayakan kredit berdasarkan sejumlah atribut keuangan dan karakteristik pemohon [11]. Model ini menunjukkan bahwa pendekatan Bayesian tetap efektif digunakan pada tugas klasifikasi probabilistik karena memiliki struktur yang sederhana, cepat, dan dapat bekerja dengan data latih yang terbatas [11]. Namun, berbeda dengan *Bayesian Network* penuh, *Naive Bayes* tidak memodelkan relasi kompleks antar fitur karena bergantung pada asumsi independensi kondisional terhadap kelas. Oleh karena itu, *Naive Bayes* dapat dipahami sebagai bentuk pendekatan Bayesian yang berguna untuk klasifikasi risiko sederhana, tetapi kurang memadai ketika hubungan antar variabel risiko perlu direpresentasikan secara eksplisit [11].

Penelitian lain menunjukkan bahwa efektivitas *Bayesian Network* sangat dipengaruhi oleh kualitas struktur DAG yang digunakan. Pada studi prediksi *late morbidity*, struktur *Bayesian Network* dioptimalkan menggunakan *simulated annealing* karena struktur bawaan yang dihasilkan secara otomatis belum tentu logis atau sesuai dengan hubungan kausal yang diharapkan [10]. Temuan ini menegaskan bahwa *Bayesian Network* memiliki kekuatan pada kemampuan representasi dependensi, tetapi sekaligus sangat bergantung pada bagaimana struktur hubungan antar variabel dibangun [10]. Jika struktur DAG yang dihasilkan kurang tepat, maka kualitas inferensi, interpretabilitas, dan relevansi hasil keputusan juga dapat menurun. Dengan demikian, keunggulan *Bayesian Network* dalam *probabilistic modeling* tidak dapat dipisahkan dari tantangan dalam proses *structure learning* serta kebutuhan akan pengetahuan pakar untuk membatasi atau memvalidasi arah hubungan antarnode [9], [10].

Bayesian Network juga menghadapi keterbatasan pada data kontinu besar dan sistem berdimensi tinggi. Pada data industri muncul tantangan heterogenitas data dan kompleksitas struktur [9] pada studi klinis variabel kontinu perlu didiskretisasi terlebih dahulu [10] sedangkan pada *structural health monitoring* muncul *curse of dimensionality* dan kompleksitas komputasi pada sistem dinamis berskala besar [12]. Berdasarkan berbagai penelitian tersebut, *Bayesian Network* merupakan metode yang kuat untuk *probabilistic reasoning* dan pemodelan risiko karena mampu merepresentasikan ketergantungan antar variabel [9]–[12], tetapi belum cukup apabila digunakan sendiri untuk membangun sistem deteksi risiko yang menuntut kemampuan identifikasi anomali sekaligus penalaran probabilistik secara terpadu. Kondisi ini menegaskan perlunya pendekatan pelengkap yang menghubungkan kekuatan deteksi anomali dengan kemampuan pemodelan risiko dalam satu kerangka.

2.1.4. Model Hybrid Dalam Machine Learning

Perkembangan penelitian *machine learning* menunjukkan bahwa penggunaan model tunggal sering kali belum cukup untuk menangani data anomali yang kompleks, terutama ketika pola penyimpangan bersifat heterogen, dinamis, dan dipengaruhi oleh banyak faktor sekaligus. Oleh karena itu, berbagai penelitian mulai mengembangkan pendekatan *hybrid* dengan menggabungkan beberapa model agar dapat memanfaatkan keunggulan masing-masing komponen. Dalam penelitian *anomaly detection*, pendekatan ini digunakan untuk meningkatkan sensitivitas deteksi, memperbaiki stabilitas hasil, dan mengurangi kelemahan yang muncul apabila hanya satu model digunakan secara mandiri [14], [15], [16], [21], [22].

Sejumlah penelitian memperlihatkan bahwa *hybrid anomaly detection* dapat dibangun melalui penggabungan model *supervised* dan *unsupervised*. Pada deteksi *fraud* kartu kredit, kerangka XRAI mengintegrasikan *XGBoost*, *Random Forest*, *Autoencoder*, dan *Isolation Forest* dalam satu sistem *heterogeneous weighted ensemble* [14]. Integrasi dilakukan melalui normalisasi skor masing-masing model ke rentang yang sama, kemudian digabungkan dengan *weighted sum* dan *thresholding* untuk menghasilkan keputusan akhir [14]. Strategi ini menunjukkan bentuk *score-level fusion*, yaitu penggabungan keluaran model pada level skor, bukan pada level fitur atau representasi. Hasil penelitian menunjukkan bahwa

pendekatan tersebut mampu memberikan *recall*, *precision*, dan *F1-score* yang lebih baik dibandingkan beberapa model pembanding, meskipun tetap menghadapi isu kompleksitas model dan tingginya *false positive* dari beberapa komponen tertentu [14]. Temuan ini menunjukkan bahwa pendekatan *hybrid* dapat meningkatkan performa deteksi, tetapi kualitas hasil tetap bergantung pada cara skor dari masing-masing model digabungkan.

Selain penggabungan skor antarmodel, penelitian lain menunjukkan bahwa integrasi *hybrid* juga dapat dilakukan melalui kombinasi antara komponen *unsupervised* dan inferensi probabilistik. Pada sistem *monitoring* pompa pendingin reaktor nuklir, pendekatan *Kernel Self-Organizing Map* dipadukan dengan *Bayesian Posterior Inference* untuk membangun mekanisme deteksi anomali yang lebih dapat ditelusuri [15]. Dalam pendekatan ini, *Kernel SOM* digunakan untuk memodelkan pola normal secara *unsupervised*, sedangkan distribusi probabilitas jarak antar *cluster* dimanfaatkan untuk menghitung probabilitas *posterior* keadaan normal [15]. Integrasi semacam ini tidak sepenuhnya berada pada *score-level fusion* klasik maupun *feature-level fusion*, melainkan lebih mendekati penggabungan representasi lokal dengan mekanisme penalaran probabilistik. Penelitian lain pada *structural health monitoring* juga menunjukkan pola serupa, yaitu memanfaatkan *manifold learning-aided data clustering* dan *non-parametric probabilistic anomaly detection* untuk membangun *anomaly score* berdasarkan subset lokal data [21]. Kedua penelitian tersebut menunjukkan bahwa model *unsupervised* dapat dipadukan dengan komponen probabilistik untuk meningkatkan reliabilitas deteksi, terutama pada data yang dipengaruhi variasi lingkungan dan pola lokal yang kompleks [15], [21].

Perbedaan strategi integrasi juga terlihat pada penelitian yang menekankan *decision-level* maupun *feature-level fusion*. Pada deteksi anomali kapsul endoskopi, beberapa *base learner* berupa *autoencoder*, *autoencoder* dengan *classification head*, dan *image classifier* digabungkan melalui *meta-classifier Random Forest* atau *SVM* [22]. Pendekatan ini memperlihatkan bentuk *decision-level fusion*, karena prediksi dari model tingkat bawah dipelajari kembali untuk menghasilkan keputusan akhir [22]. Sementara itu, pada sistem *Industrial Control Systems* (ICS), integrasi dilakukan melalui dua tahap, yaitu *feature augmentation* dan *weighted score aggregation* [16]. Skor anomali dari *Autoencoder* dan *Isolation Forest* terlebih

dahulu digunakan sebagai fitur tambahan bagi *XGBoost* dan *Random Forest*, kemudian skor dari seluruh komponen diagregasi kembali untuk menghasilkan keputusan akhir [16]. Dengan demikian, penelitian ini memperlihatkan bahwa pendekatan *hybrid* tidak hanya dilakukan pada level skor, tetapi juga dapat dibangun pada level fitur. Perbedaan ini penting karena *score-level fusion* cenderung lebih sederhana dan fleksibel, sedangkan *feature-level fusion* berpotensi menangkap hubungan antarkomponen secara lebih kaya, meskipun dengan kompleksitas integrasi yang lebih tinggi [14], [16], [22].

Berdasarkan berbagai penelitian tersebut, model *hybrid* dalam *machine learning* telah dikembangkan melalui strategi integrasi yang beragam, yaitu *score-level fusion*, *decision-level fusion*, *feature-level fusion*, dan penggabungan representasi lokal dengan *probabilistic inference* [14], [16], [21], [22]. Sebagian besar penelitian masih berfokus pada penggabungan model untuk meningkatkan akurasi deteksi, dan integrasi yang secara eksplisit memanfaatkan *Isolation Forest* dan *Bayesian Network* dalam satu arsitektur terpadu masih terbatas. Kondisi ini menyisakan celah penting yang menjadi fokus penelitian ini, yaitu pengembangan model *hybrid* berbasis *feature-level fusion* yang menghubungkan keunggulan deteksi anomali *Isolation Forest* dengan kemampuan penalaran risiko *Bayesian Network*.

2.1.5. Deteksi Risiko *Multi-Domain* Pada Sektor Pertanian

Penelitian mengenai risiko pada sektor pertanian menunjukkan bahwa sumber ketidakpastian dalam sistem pertanian tidak hanya berasal dari satu faktor, tetapi terbentuk dari berbagai *layer* yang saling memengaruhi, seperti risiko harga, risiko cuaca, risiko organisme pengganggu tanaman (OPT), risiko distribusi, risiko tindakan pengelolaan, dan risiko produksi. Meskipun demikian, sebagian besar penelitian terdahulu masih memodelkan risiko tersebut secara terpisah sesuai fokus domain masing-masing. Akibatnya, pemahaman yang dihasilkan sering kali terbatas pada satu jenis gangguan tertentu dan belum sepenuhnya menggambarkan hubungan antar-*layer* risiko dalam sistem pertanian secara menyeluruh [3], [8], [23], [24].

Pada risiko harga, penelitian umumnya menempatkan volatilitas harga komoditas sebagai bentuk utama ketidakpastian yang memengaruhi keberlanjutan usaha pertanian. Salah satu studi menunjukkan bahwa kondisi meteorologis berpengaruh kuat terhadap volatilitas harga komoditas, sehingga integrasi data iklim

mampu meningkatkan prediksi volatilitas dan perancangan mekanisme lindung nilai seperti *minimum support price* dan skema asuransi [23]. Meskipun penelitian tersebut telah menghubungkan harga dengan cuaca dan instrumen keuangan, integrasi yang dilakukan masih berpusat pada *layer* ekonomi-finansial dan belum menghubungkannya dengan risiko biologis seperti OPT maupun risiko distribusi secara operasional [23]. Hal ini menunjukkan bahwa pada domain harga, perluasan variabel telah mulai dilakukan, tetapi belum berkembang menjadi pemodelan risiko pertanian yang benar-benar lintas *layer*.

Pada risiko OPT, penelitian terdahulu banyak memanfaatkan *early warning system* berbasis prakiraan cuaca untuk memperkirakan potensi wabah penyakit atau gangguan tanaman. Studi pada penyakit *wheat blast* menunjukkan bahwa suhu, curah hujan, kelembapan relatif, dan variabel lingkungan lain dapat digunakan untuk membangun sistem peringatan dini yang tervalidasi dan diadopsi secara luas oleh pengguna lapangan [8]. Temuan ini memperlihatkan bahwa risiko OPT telah dimodelkan secara cukup baik dengan menghubungkan faktor biologis dan cuaca. Namun, integrasi tersebut tetap terbatas pada hubungan antara penyakit dan faktor lingkungan, tanpa menghubungkannya lebih lanjut dengan dampak terhadap harga, distribusi, atau keputusan rantai pasok secara lebih luas [8]. Dengan demikian, studi pada domain OPT masih menunjukkan kecenderungan untuk berhenti pada *layer* biologis dan agroklimat, bukan pada integrasi risiko pertanian yang menyeluruh.

Pada risiko distribusi, penelitian banyak berfokus pada gangguan logistik dan pascapanen, terutama pada sistem rantai dingin untuk komoditas yang mudah rusak. Studi mengenai ekspor durian dari Thailand ke China mengidentifikasi 16 faktor risiko pada rantai dingin, mulai dari kekurangan pasokan, kekurangan kontainer, kerusakan alat pengendali suhu, hingga persoalan sertifikasi [24]. Penelitian ini memperlihatkan bahwa distribusi pertanian memiliki kerentanan yang nyata dan dapat dianalisis sebagai domain risiko tersendiri. Namun, walaupun mencakup beberapa jenis risiko operasional dan pasokan, penelitian tersebut belum menghubungkannya secara langsung dengan risiko harga, cuaca, maupun OPT dalam satu model terpadu [24]. Hal ini menunjukkan bahwa pada *layer* distribusi, penelitian masih dominan menilai risiko logistik secara spesifik dan belum menempatkannya sebagai bagian dari sistem risiko pertanian yang saling terhubung.

Sementara itu, pada risiko cuaca, penelitian menunjukkan bahwa variabilitas dan kejutan iklim dapat memengaruhi hasil produksi, pendapatan petani, hingga risiko gagal bayar kredit. Studi empiris di Brazil menunjukkan bahwa komponen iklim seperti tren, musim, *covariate shocks*, dan *idiosyncratic shocks* dapat menjelaskan lebih dari separuh variasi hasil, serta berimplikasi pada peningkatan volatilitas pendapatan dan risiko kredit di masa depan [3]. Temuan ini menegaskan bahwa risiko cuaca tidak hanya berdampak pada produksi, tetapi juga menjalar ke aspek ekonomi pertanian. Meskipun demikian, integrasi yang dibangun masih berpusat pada rantai cuaca-produksi-pendapatan-kredit, dan belum menyatukan secara langsung risiko harga, OPT, dan distribusi dalam satu kerangka yang sama [3]

Berdasarkan berbagai penelitian tersebut, dapat dilihat bahwa risiko pada sektor pertanian memang telah dimodelkan pada berbagai domain, tetapi sebagian besar masih dilakukan secara terpisah atau hanya menghubungkan dua sampai tiga *layer* risiko secara terbatas [3], [8], [23]. Risiko harga cenderung dikaitkan dengan cuaca dan instrumen keuangan [23], risiko OPT banyak dipadukan dengan faktor agroklimat untuk *early warning* [8], risiko distribusi dianalisis pada level logistik dan pascapanen [24], sedangkan risiko cuaca sering diperluas hingga dampaknya pada produksi dan pendapatan [3]. Namun, belum banyak penelitian yang menyatukan domain harga, cuaca, OPT, distribusi, tindakan pengelolaan, dan produksi secara simultan dalam satu kerangka deteksi risiko pertanian. Kondisi ini menunjukkan bahwa penelitian pada sektor pertanian masih menyisakan kebutuhan akan pendekatan *multi-domain* yang mampu memodelkan keterkaitan antar-*layer* risiko secara lebih terpadu dan operasional.

2.1.6. Sistem Peringatan Dini Berbasis AI

Penelitian mengenai sistem peringatan dini berbasis *AI* menunjukkan bahwa peran model prediktif tidak berhenti pada proses deteksi atau klasifikasi, tetapi berlanjut pada pembentukan mekanisme peringatan yang dapat digunakan untuk mendukung keputusan operasional. Dalam berbagai studi, sistem peringatan dini dibangun dengan pola umum berupa pengumpulan data multivariat atau multimodal, pembentukan skor risiko prediktif, kemudian penerjemahan skor tersebut menjadi *alert* melalui ambang tertentu. Pola ini menunjukkan bahwa efektivitas *early warning system* tidak hanya ditentukan oleh kemampuan model mengenali pola

risiko, tetapi juga oleh cara risiko tersebut dikonversi menjadi sinyal peringatan yang relevan, tepat waktu, dan dapat ditindaklanjuti [25]–[28].

Pada sektor pertanian, pendekatan berbasis *AI* mulai digunakan untuk membangun sistem peringatan dini yang menggabungkan berbagai sumber data secara simultan. Salah satu penelitian mengembangkan *MSPEW-Net*, yaitu sistem peringatan dini berbasis *predictive inference* yang memanfaatkan data stres lingkungan, citra *UAV* atau satelit, serta pola propagasi penyakit tanaman untuk menghasilkan skor risiko probabilistik [25]. Skor tersebut kemudian digunakan untuk memicu *alert* dengan sensitivitas yang disesuaikan terhadap area dan jenis tanaman. Penelitian lain pada sistem penyimpanan gandum mengembangkan kerangka *deep learning* yang menggabungkan klasifikasi kondisi saat ini dengan prediksi distribusi suhu masa depan untuk mendeteksi risiko kondensasi dan *mildew* [26]. Temuan ini menunjukkan bahwa dalam sistem *agrifood*, *AI-based early warning* tidak hanya berfungsi sebagai alat prediksi, tetapi juga sebagai mekanisme identifikasi kondisi abnormal yang berpotensi menimbulkan kerugian operasional [25], [26].

Selain penerapannya pada pertanian dan penyimpanan pangan, penelitian di bidang klinis memberikan gambaran yang lebih jelas mengenai bagaimana *alert generation framework* dan *risk scoring mechanism* dievaluasi secara sistematis. Studi yang membandingkan beberapa *early warning scores* menunjukkan bahwa sistem peringatan dapat dibangun dengan dua pendekatan utama, yaitu pendekatan *rule-based* dan pendekatan *ML-based* [27]. Pendekatan *rule-based* seperti *MEWS*, *NEWS*, dan *NEWS2* biasanya menggunakan skor agregat berbasis aturan dan ambang risiko tertentu, sehingga relatif lebih transparan dan mudah dipahami. Sebaliknya, pendekatan *ML-based* seperti *eCART*, *EDI*, dan *RI* memanfaatkan pola data yang lebih kompleks untuk menghasilkan skor risiko yang lebih adaptif [27]. Perbandingan ini menunjukkan bahwa sistem berbasis *AI* cenderung memberikan kemampuan diskriminasi yang lebih baik, tetapi keunggulan tersebut tidak hanya bergantung pada model, melainkan juga pada desain ambang *alert*, *lead time*, serta beban alarm yang ditimbulkan [27].

Pentingnya evaluasi terhadap *false positive* juga terlihat jelas pada penelitian yang memvalidasi sistem *VC-MAES* untuk memprediksi *major adverse events* di bangsal rumah sakit [28]. Dalam penelitian tersebut, model *deep learning*

menghasilkan skor 0–100 yang terus diperbarui secara *real-time*, lalu dibandingkan dengan *NEWS* dan *MEWS* melalui evaluasi *sensitivity*, *specificity*, *positive predictive value*, dan *false positives per true positive* [28]. Hasilnya menunjukkan bahwa sistem berbasis *AI* dapat menurunkan *false positive burden* secara signifikan dibandingkan pendekatan konvensional. Temuan ini penting karena sistem peringatan dini yang terlalu sering menghasilkan alarm berlebih dapat menimbulkan *alert fatigue*, menurunkan kepercayaan pengguna, serta membebani sumber daya operasional [27], [28]. Dengan demikian, tantangan utama dalam *AI-based early warning system* bukan hanya meningkatkan akurasi prediksi, tetapi juga menjaga agar kualitas *alert* tetap seimbang antara sensitivitas, ketepatan, dan utilisasi praktis di lapangan.

Berdasarkan berbagai penelitian tersebut, dapat dilihat bahwa sistem peringatan dini berbasis *AI* umumnya dibangun melalui kombinasi model prediktif, skor risiko, dan mekanisme *alert* berbasis ambang tertentu [25]–[28]. Pendekatan *ML-based* menunjukkan potensi yang lebih tinggi dibandingkan sistem *rule-based* yang lebih kaku, tetapi keunggulan tersebut tetap bergantung pada desain mekanisme *alert generation* dan pengendalian *false positive* [25]–[28]. Oleh karena itu, pengembangan sistem peringatan dini perlu mempertimbangkan tidak hanya kemampuan model mendeteksi risiko, tetapi juga bagaimana hasil deteksi diterjemahkan menjadi peringatan yang operasional dan reliabel. Oleh karena itu, pengembangan sistem peringatan dini pada penelitian ini tidak cukup hanya berfokus pada kemampuan model mendeteksi risiko, tetapi juga harus mempertimbangkan bagaimana hasil deteksi diterjemahkan menjadi peringatan yang operasional, reliabel, dan tidak menimbulkan alarm berlebih. Kondisi ini menegaskan bahwa sistem deteksi risiko yang baik perlu didukung oleh mekanisme *risk scoring* dan *alert generation* yang terstruktur agar dapat berfungsi sebagai *early warning system* yang benar-benar berguna.

2.1.7. Ringkasan dan Posisi Penelitian

Berdasarkan kajian terhadap berbagai penelitian terdahulu, dapat disimpulkan bahwa deteksi anomali, pemodelan risiko, model *hybrid*, dan sistem peringatan dini telah berkembang cukup luas pada berbagai bidang, termasuk sistem industri, keamanan digital, pemantauan operasional, serta sektor pertanian. Dalam penelitian-penelitian tersebut, pendekatan yang digunakan umumnya terbagi ke dalam beberapa kelompok utama, yaitu pendekatan berbasis deteksi anomali *unsupervised* seperti *Isolation Forest*, pendekatan probabilistik berbasis *Bayesian Network*, termasuk varian *classifier* yang lebih sederhana seperti *Naive Bayes*, pendekatan *hybrid* yang menggabungkan beberapa model, serta sistem *early warning* berbasis skor risiko dan *alert generation*.

Pendekatan berbasis *Isolation Forest* menunjukkan keunggulan dalam mendeteksi anomali pada data multivariat dan berdimensi tinggi tanpa memerlukan data berlabel. Metode ini efektif untuk mendeteksi observasi yang menyimpang melalui mekanisme isolasi acak, tetapi kinerjanya sensitif terhadap pengaturan parameter seperti *contamination* dan masih memiliki keterbatasan dalam interpretabilitas probabilistik. Di sisi lain, *Bayesian Network* unggul dalam memodelkan ketergantungan antar variabel serta mendukung inferensi risiko melalui probabilitas *posterior*. Namun, pendekatan ini sangat dipengaruhi oleh kualitas struktur *directed acyclic graph* (DAG) dan menghadapi tantangan komputasional ketika diterapkan pada data kontinu besar atau struktur yang kompleks.

Sejumlah penelitian juga telah mengembangkan pendekatan *hybrid* untuk meningkatkan performa deteksi risiko dan anomali. Model *hybrid* umumnya dibangun melalui kombinasi komponen *unsupervised*, *supervised*, atau komponen probabilistik, baik pada level skor, fitur, maupun inferensi. Akan tetapi, sebagian besar penelitian masih berfokus pada domain tertentu dan belum secara eksplisit mengintegrasikan *Isolation Forest* dengan *Bayesian Network* dalam satu kerangka deteksi risiko yang terpadu. Pada saat yang sama, penelitian mengenai sistem peringatan dini berbasis AI menunjukkan bahwa hasil model prediktif umumnya diterjemahkan ke dalam bentuk skor risiko dan *alert* berbasis ambang tertentu. Namun, tantangan seperti *false positive*, beban alarm, dan reliabilitas *alert* masih menjadi persoalan penting dalam penerapan operasional.

Dalam sektor pertanian, penelitian terdahulu telah memodelkan berbagai jenis risiko, seperti risiko harga, risiko cuaca, risiko organisme pengganggu tanaman, risiko distribusi, risiko tindakan pengelolaan, dan risiko produksi. Meskipun demikian, pemodelan tersebut umumnya masih dilakukan secara terpisah atau hanya menghubungkan dua sampai tiga *layer* risiko secara terbatas. Belum banyak penelitian yang menangani berbagai domain risiko pertanian, seperti harga, cuaca, OPT, distribusi, tindakan pengelolaan, dan produksi, dalam satu kerangka deteksi risiko *multi-domain* yang tetap mempertahankan karakteristik masing-masing domain dan terhubung dengan mekanisme peringatan dini. Oleh karena itu, masih terdapat kebutuhan akan pendekatan yang mampu menghubungkan deteksi anomali, inferensi probabilistik, integrasi *multi-domain*, dan *risk alerting* dalam satu kerangka yang operasional.

Untuk memperjelas posisi penelitian, Tabel 2.1 menyajikan ringkasan lima penelitian terdahulu yang paling relevan.

Tabel 2.1 Ringkasan Penelitian Terdahulu

No	Peneliti & Tahun	Domain	Pendekatan	Fitur yang Digunakan	Metode Evaluasi	Hasil Utama	Keterbatasan
1	Burney et al. (2024) [3]	Agricultural risks	Pemodelan empiris risiko iklim	Komponen cuaca, yield, revenue, loan default	R^2 , within R^2	Risiko iklim menjelaskan >50% variasi hasil pertanian	Belum mengintegrasikan OPT dan distribusi dalam satu model
2	Claudia et al. (2025) [18]	Anomaly detection	Isolation Forest + hyperparameter tuning	Fitur biner permission request Android	Precision, Recall, F1, FPR, TPR	IF efektif; tuning menurunkan false positive hingga 50%	Sensitif terhadap contamination; tidak memberi reasoning probabilistik
3	Stenhouse et al. (2025) [9], [10]	Risk modeling	Bayesian Network + simulated annealing	39 faktor risiko klinis; diskretisasi KMeans	Balanced accuracy, F1 macro, ROC-AUC	BN mampu memodelkan dependensi variabel risiko kompleks	Bergantung pada kualitas DAG; domain klinis, bukan pertanian

Tabel 2.1 (lanjutan)

No	Peneliti & Tahun	Domain	Pendekatan	Fitur yang Digunakan	Metode Evaluasi	Hasil Utama	Keterbatasan
4	Wang et al. (2025) [15]	Hybrid anomaly detection	Kernel SOM + Bayesian Posterior Inference	Data monitoring pompa; distribusi probabilitas jarak cluster	Precision, Recall, F1, lag time	Integrasi unsupervised dan probabilistik meningkatkan interpretabilitas	Belum menggunakan IF + BN; masih spesifik satu domain
5	Shyam et al. (2025) [25]	Early warning pertanian	AI-based EWS; deep learning multimodal	Sensor lingkungan, citra UAV/satelit, pola penyakit	Overall accuracy	Accuracy 94,2%; menghasilkan skor risiko probabilistik dan alert dini	Tidak mengintegrasikan seluruh layer risiko rantai pasok pertanian

Analisis *Research Gap* dalam penelitian ini adalah sebagai berikut:

- Sebagian besar penelitian masih menggunakan pendekatan tunggal, baik deteksi anomali maupun pemodelan probabilistik, sehingga kemampuan untuk menangkap penyimpangan distribusional dan melakukan penalaran risiko belum dimanfaatkan secara simultan.
- Model *hybrid* yang ada belum banyak mengintegrasikan deteksi anomali berbasis isolasi dengan inferensi probabilistik berbasis jaringan Bayesian dalam satu arsitektur yang eksplisit.
- Penelitian pada sektor pertanian masih cenderung memodelkan risiko secara parsial, misalnya hanya risiko harga, hanya cuaca, hanya OPT, atau hanya distribusi.
- Belum banyak penelitian yang menangani berbagai domain risiko pertanian dalam satu kerangka deteksi risiko *multi-domain* dengan tetap mempertahankan karakteristik masing-masing domain.
- Sistem peringatan dini berbasis *AI* umumnya sudah menggunakan skor risiko dan *alert*, tetapi belum banyak yang dibangun dari integrasi deteksi anomali dan *probabilistic reasoning* untuk mendukung keputusan risiko yang lebih komprehensif.


Posisi penelitian ini adalah sebagai berikut:

- a) Mengembangkan model *hybrid* yang mengintegrasikan *Isolation Forest* dengan *Bayesian Network* dalam satu kerangka analisis risiko, dengan implementasi komponen Bayesian menggunakan struktur *classifier* yang bersifat naif berbasis label dan fitur.
- b) Menghubungkan deteksi anomali dengan inferensi probabilistik, sehingga hasil deteksi tidak berhenti pada identifikasi penyimpangan, tetapi dilanjutkan ke penalaran risiko.
- c) Menangani risiko pada beberapa domain dalam rantai pasok pertanian, yaitu harga, cuaca, OPT, distribusi, tindakan pengelolaan, dan produksi, melalui pemodelan per-domain sehingga membentuk sistem deteksi risiko multi-domain yang lebih terstruktur.
- d) Menghasilkan skor risiko *hybrid* pada setiap domain yang dapat digunakan sebagai dasar sistem peringatan dini.
- e) Memberikan kontribusi metodologis dan aplikatif pada pengembangan sistem deteksi risiko yang lebih terstruktur, operasional, dan relevan untuk sektor pertanian.

2.1.8. Kerangka Pemikiran

Rantai pasok pertanian menghadapi risiko dari beberapa domain yang saling berinteraksi, sehingga pendekatan deteksi satu domain belum mampu merepresentasikan kondisi risiko secara menyeluruh. Penelitian terdahulu masih didominasi pendekatan single-domain dan single-model yang memiliki keterbatasan masing-masing. *Isolation Forest* sesuai untuk mendeteksi anomali secara unsupervised, sedangkan *Bayesian Network* sesuai untuk memodelkan ketidakpastian probabilistik — keduanya memiliki keterbatasan yang saling melengkapi. Integrasi keduanya dalam satu kerangka *hybrid* berpotensi menghasilkan deteksi risiko multi-domain yang lebih komprehensif. Model *hybrid IF–BN* dikembangkan secara per-domain pada enam domain risiko (harga, cuaca, OPT, distribusi, tindakan pengelolaan, dan produksi) dan dievaluasi pada data multi-domain rantai pasok pertanian di Kabupaten Sumedang periode 2022–2024 dengan resolusi mingguan-kecamatan. Penelitian ini memberikan kontribusi metodologis sebagai dasar pengembangan sistem peringatan dini pada rantai pasok pertanian.

Berdasarkan alur pemikiran tersebut, kerangka penelitian ini dapat digambarkan sebagai berikut.



Gambar 2.1 Kerangka Pemikiran

2.2. Tinjauan Pustaka

2.2.1. Konsep Risiko dan Ketidakpastian

Risiko merupakan konsep yang berkaitan dengan kemungkinan terjadinya suatu kejadian yang menimbulkan konsekuensi tertentu di bawah kondisi ketidakpastian [29]. Risiko tidak hanya berhubungan dengan peluang kerugian, tetapi juga dengan kondisi ketika keputusan harus diambil meskipun hasil akhirnya belum dapat diketahui secara pasti [29]. Dalam analisis risiko, probabilitas digunakan sebagai alat kuantitatif untuk merepresentasikan derajat kemungkinan suatu kejadian, sedangkan ketidakpastian menggambarkan keterbatasan pengetahuan mengenai apakah, kapan, dan seberapa besar suatu kejadian akan terjadi. Penilaian risiko dibangun dari kombinasi keduanya, karena keputusan nyata hampir selalu dilakukan di bawah informasi yang tidak sempurna [29].

Pada sistem dinamis, risiko menjadi lebih kompleks karena kondisi sistem berubah terhadap waktu dan dipengaruhi oleh banyak faktor yang saling berinteraksi [30]. Ketidakpastian pada sistem seperti ini tidak hanya berasal dari kondisi awal atau gangguan eksternal, tetapi juga dari bagaimana ketidakpastian tersebut merambat sepanjang perkembangan sistem [30]. Artinya, perubahan kecil pada parameter, input, atau lingkungan dapat menghasilkan konsekuensi yang berbeda seiring berjalannya waktu [30]. Dalam situasi semacam ini, risiko tidak lagi dipahami sebagai nilai statis, melainkan sebagai sesuatu yang berkembang secara temporal sesuai dinamika sistem [27].

Dengan demikian, konsep risiko dan ketidakpastian memberikan landasan penting bagi penelitian ini. Secara umum, risiko dipahami sebagai kemungkinan munculnya konsekuensi yang merugikan di bawah kondisi ketidakpastian, sedangkan probabilitas digunakan sebagai sarana untuk merepresentasikan kemungkinan tersebut. Namun, dalam konteks penelitian ini, risiko dipahami secara operasional sebagai kondisi penyimpangan signifikan pada indikator domain yang dapat berfungsi sebagai sinyal awal potensi gangguan pada rantai pasok pertanian. Pada sistem yang dinamis seperti rantai pasok pertanian, penyimpangan tersebut dapat berubah mengikuti interaksi antara faktor lingkungan, operasional, dan ekonomi. Oleh karena itu, pemahaman terhadap risiko, probabilitas, ketidakpastian, dan anomali menjadi dasar konseptual yang penting sebelum membahas karakteristik risiko pada rantai pasok pertanian.

2.2.2. Rantai Pasok Pertanian dan Karakteristik Risikonya

Rantai pasok pertanian merupakan sistem yang menghubungkan berbagai tahapan kegiatan mulai dari produksi di tingkat petani, penanganan pascapanen, pengolahan, distribusi, hingga produk sampai kepada konsumen akhir [1]. Berbeda dari rantai pasok pada sektor manufaktur, rantai pasok pertanian memiliki karakteristik yang lebih sensitif terhadap faktor alam, kualitas produk yang mudah menurun, serta ketergantungan tinggi pada koordinasi antar pelaku dari hulu hingga hilir [1]. Struktur ini membuat aliran barang, informasi, dan keputusan dalam sistem pertanian sangat dipengaruhi oleh kondisi produksi, infrastruktur distribusi, regulasi, serta perubahan pasar [1].

Salah satu karakteristik penting dalam rantai pasok pertanian adalah volatilitas harga. Harga komoditas pertanian cenderung berfluktuasi akibat perubahan penawaran dan permintaan, kondisi pasar, kebijakan, serta tekanan eksternal yang berkaitan dengan faktor agronomis dan iklim [2]. Risiko harga menjadi penting karena perubahan harga tidak hanya memengaruhi pendapatan produsen, tetapi juga memengaruhi keputusan pengadaan, penyimpanan, distribusi, dan konsumsi [2]. Dengan demikian, volatilitas harga dalam sektor pertanian tidak dapat dipisahkan dari dinamika produksi dan perubahan lingkungan yang memengaruhi stabilitas pasar [2].

Karakteristik berikutnya adalah ketergantungan terhadap cuaca. Produksi pertanian sangat dipengaruhi oleh curah hujan, suhu, kekeringan, banjir, gelombang panas, dan berbagai bentuk anomali iklim lainnya [1], [2]. Ketergantungan ini menjadikan rantai pasok pertanian lebih rentan terhadap gangguan dibandingkan banyak sektor lain, karena perubahan cuaca dapat berdampak langsung pada hasil panen, kualitas produk, ketersediaan pasokan, dan akhirnya harga di pasar [1], [2]. Dengan demikian, cuaca tidak hanya menjadi faktor produksi, tetapi juga menjadi sumber risiko yang memengaruhi stabilitas keseluruhan rantai pasok pertanian.

Selain itu, rantai pasok pertanian juga memiliki kerentanan distribusi yang tinggi [1]. Kerentanan ini muncul karena produk pertanian umumnya bersifat mudah rusak, memerlukan penanganan khusus, bergantung pada infrastruktur transportasi dan penyimpanan, serta sensitif terhadap keterlambatan dan gangguan logistik [1]. Pada sistem *agri-food* modern, distribusi yang terganggu dapat menyebabkan kehilangan kualitas, peningkatan biaya, keterlambatan pasokan, dan bahkan memperbesar kerugian ekonomi di berbagai titik rantai pasok [1]. Oleh karena itu, rantai pasok pertanian dapat dipahami sebagai sistem yang secara inheren menghadapi kombinasi risiko harga, ketergantungan cuaca, dan kerentanan distribusi, sehingga membutuhkan pendekatan analisis risiko yang lebih terintegrasi [1], [2].

2.2.3. Teori *Anomaly Detection*

Anomaly detection merupakan proses identifikasi data, pola, atau kejadian yang menyimpang secara signifikan dari perilaku normal suatu sistem [31]. Dalam banyak kasus, anomali dipahami sebagai observasi yang tidak mengikuti distribusi umum data atau menunjukkan karakteristik yang berbeda dibandingkan mayoritas objek lain. Keberadaan anomali sering dikaitkan dengan kejadian yang jarang muncul, tidak terduga, atau berpotensi menimbulkan gangguan terhadap sistem yang diamati. Oleh karena itu, *anomaly detection* banyak digunakan dalam berbagai bidang, seperti keamanan siber, pemantauan industri, kesehatan, keuangan, hingga sistem pertanian, karena mampu membantu mengenali kondisi tidak normal sebelum berkembang menjadi risiko yang lebih besar [31].

Secara umum, anomali dapat dibedakan menjadi tiga tipe utama, yaitu *point anomaly*, *contextual anomaly*, dan *collective anomaly* [31]. *Point anomaly* terjadi ketika satu observasi tunggal menunjukkan penyimpangan yang jelas dibandingkan data normal di sekitarnya. *Contextual anomaly* muncul ketika suatu observasi dianggap normal dalam satu situasi, tetapi menjadi anomali pada konteks tertentu, misalnya berdasarkan waktu, lokasi, atau kondisi lingkungan. Sementara itu, *collective anomaly* terjadi ketika sekelompok data secara bersama-sama membentuk pola yang tidak wajar, meskipun tiap titik data secara individual belum tentu terlihat menyimpang [31]. Pembagian ini menunjukkan bahwa anomali tidak selalu berbentuk nilai ekstrem tunggal, tetapi dapat juga muncul sebagai pola yang hanya dapat dikenali melalui hubungan antar data atau melalui konteks kemunculannya.

Berdasarkan ketersediaan label, pendekatan *anomaly detection* dibedakan menjadi *supervised*, *semi-supervised*, dan *unsupervised* [31]. Pada sistem nyata, data anomali cenderung jarang, tidak seimbang, dan sulit dilabeli secara konsisten, sehingga pendekatan *supervised* sering tidak praktis [32]. Pendekatan *unsupervised* menjadi lebih relevan karena tidak memerlukan label anomali pada tahap pelatihan, melainkan mendeteksi penyimpangan berdasarkan pola intrinsik data normal [31], [32]. Pendekatan ini juga lebih fleksibel pada data deret waktu dan multivariat dengan ketidakpastian tinggi [32]. Dalam penelitian ini, pendekatan *unsupervised* menjadi relevan karena risiko pada rantai pasok pertanian dapat muncul dalam berbagai bentuk penyimpangan yang tidak selalu tersedia labelnya secara lengkap.

2.2.4. Teori *Isolation Forest*

Setelah penerapan *Isolation Forest* dalam penelitian terdahulu diuraikan pada Subbab 2.1.2, subbab ini menguraikan landasan teori metode tersebut. *Isolation Forest* merupakan metode *unsupervised anomaly detection* yang dibangun atas asumsi bahwa anomali umumnya lebih sedikit jumlahnya dan memiliki karakteristik yang lebih mudah dipisahkan dibandingkan data normal [33].

Konsep utama dalam *Isolation Forest* adalah *path length*, yaitu panjang lintasan dari akar pohon sampai suatu observasi mencapai simpul terminal [34]. Semakin pendek lintasan suatu data, semakin besar kemungkinan data tersebut merupakan anomali, karena data tersebut dapat dipisahkan dengan lebih sedikit langkah [34]. Oleh karena itu, keputusan anomali dalam *Isolation Forest* ditentukan berdasarkan *expected path length*, yaitu rata-rata panjang lintasan suatu observasi pada seluruh pohon dalam hutan isolasi [34]. Nilai ini kemudian dibandingkan dengan panjang lintasan rata-rata yang diharapkan pada pohon pencarian biner acak, sehingga diperoleh dasar untuk membedakan antara data normal dan data yang menyimpang [34].

Agar skor anomali dapat diperbandingkan secara konsisten, *Isolation Forest* menggunakan normalisasi terhadap *expected path length* melalui faktor $c(n)$, yaitu estimasi panjang lintasan rata-rata pada pohon acak dengan ukuran sampel n [34]. Dengan normalisasi tersebut, skor anomali tidak hanya bergantung pada panjang lintasan mentah, tetapi juga mempertimbangkan ukuran subsampel yang digunakan saat membangun pohon [34]. Secara umum, skor yang mendekati 1 menunjukkan kecenderungan kuat bahwa suatu observasi adalah anomali, sedangkan skor yang lebih rendah menunjukkan bahwa observasi tersebut lebih dekat pada pola data normal [34]. Mekanisme ini memberikan dasar statistik yang lebih kuat dalam interpretasi skor *Isolation Forest*.

Dari sisi komputasi, *Isolation Forest* dikenal efisien karena setiap pohon dibangun menggunakan subsampel acak berukuran terbatas, bukan seluruh data secara penuh [33]. Karakteristik ini membuat metode tersebut relatif ringan dalam kebutuhan waktu dan memori dibandingkan pendekatan yang memerlukan perhitungan pasangan jarak secara menyeluruh atau estimasi distribusi berdimensi tinggi [33]. Selain itu, pendekatan isolasi acak juga membuat *Isolation Forest* cukup

skalabel untuk data multivariat [33]. Dengan demikian, *Isolation Forest* dapat dipahami sebagai metode deteksi anomali yang memanfaatkan *random partitioning*, *expected path length*, normalisasi skor, dan efisiensi komputasi untuk mengenali penyimpangan data secara efektif, sehingga relevan digunakan sebagai landasan metode dalam penelitian ini [33], [34].

2.2.5. Teori *Bayesian Network*

Setelah penerapan *Bayesian Network* dalam penelitian terdahulu diuraikan pada Subbab 2.1.3, subbab ini menguraikan landasan teori metode tersebut. *Bayesian Network* merupakan model graf probabilistik yang digunakan untuk merepresentasikan hubungan ketergantungan antar variabel dalam suatu sistem melalui struktur *Directed Acyclic Graph* (DAG) [12], [13]. Dalam model ini, setiap *node* merepresentasikan variabel acak, sedangkan setiap *edge* menunjukkan adanya hubungan ketergantungan probabilistik antar variabel [12], [13]. Dasar teoritis *Bayesian Network* berasal dari Teorema Bayes, yaitu prinsip pembaruan probabilitas suatu kejadian berdasarkan informasi baru yang diamati. Melalui prinsip ini, *Bayesian Network* memungkinkan perhitungan probabilitas *posterior* secara sistematis ketika terdapat bukti atau observasi baru [13].

Hubungan antar variabel dalam *Bayesian Network* dinyatakan melalui *conditional probability*, yaitu probabilitas suatu variabel dengan syarat nilai variabel lain telah diketahui [12], [13]. Dengan memanfaatkan *conditional probability*, distribusi probabilitas gabungan dari seluruh variabel tidak perlu dihitung secara penuh, tetapi dapat diuraikan menjadi hasil perkalian probabilitas kondisional berdasarkan struktur DAG yang digunakan [12]. Mekanisme ini menjadikan *Bayesian Network* efisien dalam memodelkan sistem yang kompleks, karena hubungan antar variabel dapat direpresentasikan secara terstruktur sesuai dependensi yang dianggap relevan [12], [13].

Struktur DAG memiliki peran yang sangat penting dalam *Bayesian Network* karena menentukan arah hubungan antar *node* serta pola ketergantungan yang digunakan dalam inferensi [12], [13]. Sifat *acyclic* berarti grafik tidak boleh membentuk siklus, sehingga aliran dependensi berjalan secara terarah tanpa kembali ke *node* asal [12]. Dengan struktur seperti ini, *Bayesian Network* tidak hanya berfungsi sebagai representasi grafis, tetapi juga sebagai kerangka formal untuk

menunjukkan bagaimana informasi mengalir dari satu variabel ke variabel lain [12], [13]. Oleh karena itu, kualitas struktur DAG sangat menentukan kemampuan model dalam merepresentasikan hubungan probabilistik yang masuk akal dan menghasilkan inferensi yang akurat [13].

Melalui kombinasi Teorema Bayes, *conditional probability*, dan struktur DAG, *Bayesian Network* mendukung proses *probabilistic inference*, yaitu penalaran untuk menghitung probabilitas suatu variabel berdasarkan bukti pada variabel lain [12], [13]. Inferensi ini dapat bersifat diagnostik, ketika bukti digunakan untuk menelusuri kemungkinan penyebab, maupun prediktif, ketika kondisi awal digunakan untuk memperkirakan kejadian berikutnya [12]. Keunggulan tersebut menjadikan *Bayesian Network* relevan untuk pemodelan risiko dan pengambilan keputusan di bawah ketidakpastian, karena model ini mampu menghubungkan berbagai variabel secara eksplisit dan memperbarui keyakinan secara probabilistik ketika informasi baru tersedia [12], [13]. Dengan demikian, *Bayesian Network* menjadi landasan teoritis yang kuat dalam penelitian ini untuk mendukung analisis hubungan risiko dan inferensi probabilistik pada sistem yang kompleks.

Dalam penelitian ini, komponen *Bayesian Network* tidak dibangun sebagai struktur umum yang kompleks, tetapi dioperasionalkan melalui bentuk *classifier* dengan struktur naif, di mana label berperan sebagai *parent* bagi fitur-fitur observasi. Oleh karena itu, pembahasan pada subbab berikutnya difokuskan pada *Naive Bayesian Network* sebagai bentuk implementatif yang relevan dengan kebutuhan klasifikasi probabilistik dalam penelitian ini.

2.2.6. Naive Bayesian Network (Label Features)

Naive Bayesian Network merupakan bentuk paling sederhana dari *Bayesian Network Classifier*, di mana variabel kelas atau label ditempatkan sebagai *parent* bagi seluruh fitur yang digunakan dalam proses klasifikasi [35], [36]. Dalam struktur ini, setiap fitur diasumsikan bergantung langsung pada label, sehingga arah hubungan probabilistik dibangun dari label menuju fitur. Bentuk tersebut membuat model menjadi sederhana, efisien, dan mudah digunakan untuk klasifikasi karena distribusi probabilitas gabungan dapat diuraikan ke dalam probabilitas *prior* kelas dan probabilitas kondisional masing-masing fitur terhadap kelas [35], [36].

Karakteristik utama *Naive Bayesian Network* adalah asumsi *conditional independence*, yaitu setiap fitur dianggap saling bebas bersyarat setelah nilai label diketahui [35], [36]. Dengan kata lain, jika kelas suatu observasi telah ditentukan, maka nilai satu fitur dianggap tidak lagi bergantung pada fitur lain. Asumsi ini memang cukup kuat dan sering kali tidak sepenuhnya terpenuhi pada data nyata, tetapi justru menjadi dasar yang membuat *Naive Bayes* tetap sederhana dan efisien secara komputasi [36]. Dalam pengembangannya, model seperti *Tree-Augmented Naive Bayes* dan struktur berbasis *k-tree* dikembangkan untuk melonggarkan asumsi independensi penuh tersebut dengan menambahkan dependensi terbatas antar fitur, meskipun label tetap dipertahankan sebagai *node* utama dalam struktur klasifikasi [35], [36].

Dalam proses pembelajaran, parameter pada *Naive Bayesian Network* diestimasi melalui probabilitas *prior* kelas dan probabilitas kondisional fitur terhadap kelas [35], [36]. Pada pendekatan Bayesian, estimasi parameter dapat diperkuat dengan penggunaan *prior* agar probabilitas yang diperoleh lebih stabil, terutama ketika data terbatas atau terdapat kombinasi fitur-kelas yang jarang muncul. Salah satu *prior* yang dikenal dalam pembelajaran jaringan Bayesian adalah *Bayesian Dirichlet equivalent uniform (BDeu prior)*, yang dalam kondisi tertentu dapat digunakan untuk memberikan regularisasi pada estimasi parameter, terutama saat data terbatas atau terdapat kombinasi fitur-kelas yang jarang muncul. Namun, secara umum inti pembelajaran pada *Naive Bayesian Network* tetap terletak pada estimasi *prior* kelas dan probabilitas kondisional fitur terhadap kelas [35], [36].

Dengan demikian, *Naive Bayesian Network* dapat dipahami sebagai model probabilistik yang menempatkan label sebagai *parent* bagi seluruh fitur, menggunakan asumsi *conditional independence* untuk menyederhanakan perhitungan, dan mengestimasi parameter melalui probabilitas *prior* serta probabilitas kondisional yang dapat diperkuat dengan *prior* Bayesian [35], [36]. Struktur ini menjadikan *Naive Bayesian Network* efisien untuk klasifikasi probabilistik, sekaligus menjadi dasar bagi pengembangan struktur yang lebih kompleks dalam keluarga *Bayesian Network Classifiers*. Dalam penelitian ini, komponen *Bayesian Network* dioperasikan dalam bentuk *Naive Bayesian*

Network dengan estimasi parameter berbasis *Bayesian estimator* dan *BDeu prior*, yang akan diuraikan secara teknis pada Bab 3.

2.2.7. Model Hybrid Dalam Sistem Cerdas

Setelah strategi integrasi *hybrid* dalam penelitian terdahulu diuraikan pada Subbab 2.1.4, subbab ini menguraikan landasan teori model *hybrid*. Model *hybrid* merupakan pendekatan yang menggabungkan dua atau lebih metode untuk memanfaatkan keunggulan masing-masing komponen [14], [16]. Berbeda dari *ensemble* yang umumnya menggabungkan beberapa model untuk menghasilkan keputusan akhir yang lebih stabil, model *hybrid* menekankan integrasi antarkomponen yang dapat terjadi pada level fitur, skor, keputusan, maupun alur inferensi [14]. Dengan demikian, model *hybrid* tidak sekadar mengumpulkan banyak model, tetapi membangun mekanisme kerja yang saling melengkapi antara metode yang berbeda karakteristiknya.

Strategi integrasi pada model *hybrid* secara umum dapat dibedakan menjadi *score-level fusion* dan *feature-level fusion*. Pada *score-level fusion*, skor keluaran dari beberapa model dinormalisasi terlebih dahulu agar berada pada skala yang sebanding, kemudian digabungkan melalui rata-rata, penjumlahan berbobot, atau mekanisme ambang tertentu [14]. Pendekatan ini relatif sederhana karena setiap model tetap bekerja secara mandiri dan integrasi dilakukan pada tahap akhir. Sebaliknya, *feature-level fusion* dilakukan dengan menggunakan keluaran suatu model sebagai fitur tambahan bagi model lain sebelum keputusan akhir dihasilkan [16]. Strategi ini memungkinkan sistem menangkap hubungan yang lebih kaya antarkomponen, meskipun lebih kompleks dibandingkan *score-level fusion* [16]. Dalam penelitian ini, *feature-level fusion* dipilih sebagai strategi integrasi karena sesuai dengan karakteristik *Isolation Forest* sebagai penghasil skor anomali dan *Bayesian Network* sebagai mesin inferensi probabilistik berbasis fitur.

2.2.8. Integrasi Skor dan Strategi Agregasi

Dalam sistem deteksi anomali yang melibatkan lebih dari satu model, keluaran dari tiap komponen perlu diintegrasikan agar menghasilkan keputusan akhir yang konsisten [14], [16]. Integrasi dilakukan melalui strategi agregasi skor, yaitu proses menggabungkan nilai keluaran dari beberapa model ke dalam satu skor akhir yang mewakili tingkat risiko atau keabnormalan suatu observasi [14]. Pendekatan ini penting karena setiap model dapat menghasilkan skala skor yang berbeda, sehingga tanpa mekanisme agregasi yang tepat, hasil keputusan akhir dapat menjadi tidak stabil atau sulit dibandingkan secara langsung [14], [16].

Beberapa strategi agregasi yang umum digunakan adalah *mean aggregation* yang memberikan bobot setara pada setiap model, *weighted aggregation* yang memberikan bobot berbeda sesuai tingkat kepentingan model, serta *score normalization* yang menyamakan skala skor antarmodel [14], [16]. Setelah skor akhir diperoleh, tahap berikutnya adalah *thresholding*, yaitu penentuan ambang keputusan untuk membedakan kondisi normal dan kondisi berisiko, baik secara tetap maupun adaptif [14], [16]. Dalam penelitian ini, konsep normalisasi skor dan *thresholding* menjadi landasan penting untuk mekanisme integrasi hasil deteksi, sedangkan strategi *score-level aggregation* tidak digunakan secara langsung karena penelitian ini memilih *feature-level fusion*, yaitu menggunakan skor *Isolation Forest* sebagai fitur tambahan bagi *Bayesian Network*, bukan menggabungkan skor antarmodel pada tahap akhir.

2.2.9. Evaluasi Model Klasifikasi dan Deteksi Anomali

Evaluasi model deteksi anomali dilakukan untuk menilai sejauh mana model mampu membedakan antara data normal dan data anomali secara tepat [32], [37]. Dalam praktiknya, hasil prediksi model umumnya dirangkum terlebih dahulu dalam *confusion matrix*, yaitu tabel yang memuat jumlah *true positive*, *true negative*, *false positive*, dan *false negative* [32]. Berdasarkan komponen tersebut, berbagai metrik evaluasi dihitung untuk menggambarkan performa model dari sudut pandang yang berbeda. Penggunaan lebih dari satu metrik menjadi penting karena kinerja model deteksi anomali tidak dapat diwakili secara memadai hanya oleh satu ukuran, terutama pada data yang cenderung tidak seimbang [32], [37].

Metrik dasar yang paling umum digunakan adalah *precision* dan *recall* [32], [37]. *Precision* menunjukkan proporsi data yang diprediksi sebagai anomali dan benar-benar merupakan anomali, sehingga metrik ini berkaitan dengan ketepatan alarm yang dihasilkan model [32]. Sementara itu, *recall* menunjukkan proporsi anomali aktual yang berhasil dideteksi oleh model, sehingga metrik ini menggambarkan sensitivitas model terhadap kejadian menyimpang [32]. Dalam sistem deteksi anomali, kedua metrik tersebut memiliki peran yang sama penting, karena model yang terlalu sensitif dapat menghasilkan banyak *false positive*, sedangkan model yang terlalu konservatif dapat gagal mengenali anomali yang seharusnya terdeteksi [32].

Untuk menyeimbangkan kedua aspek tersebut, sering digunakan *F1-score*, yaitu rata-rata harmonik dari *precision* dan *recall* yang memberikan gambaran performa lebih seimbang ketika ketepatan dan kelengkapan deteksi sama-sama penting [32]. Selain itu, evaluasi sering menggunakan *ROC-AUC*, yang mengukur kemampuan model membedakan kelas positif dan negatif pada berbagai ambang keputusan [32], [37]. Pada data tidak seimbang, *ROC-AUC* tetap berguna untuk memberikan gambaran diskriminasi model secara umum, sedangkan kombinasi *precision*, *recall*, dan *F1-score* memberikan pandangan yang lebih spesifik terhadap kinerja deteksi pada kelas minoritas [37].

Dalam deteksi anomali, evaluasi model tidak hanya menilai performa statistik, tetapi juga relevansinya untuk penerapan nyata [32]. Metrik *confusion matrix*, *precision*, *recall*, *F1-score*, dan *ROC-AUC* memberikan sudut pandang yang berbeda terhadap kualitas deteksi, dan kombinasi kelima dapat menghasilkan penilaian yang utuh [32], [37]. Dalam penelitian ini, kelima metrik tersebut digunakan sebagai dasar evaluasi performa ketiga model (*Isolation Forest*, *Bayesian Network*, dan model *hybrid*), dengan *recall* diberikan prioritas khusus karena penelitian ini diposisikan sebagai dasar bagi sistem peringatan dini yang menempatkan keandalan deteksi anomali sebagai pertimbangan utama.

2.2.10. Penanganan *Data Imbalance*

Masalah *imbalanced classification* muncul ketika distribusi kelas dalam data tidak seimbang, sehingga jumlah observasi pada satu kelas jauh lebih besar dibandingkan kelas lainnya [38]. Kondisi ini umum dijumpai pada banyak kasus nyata, termasuk deteksi anomali, karena kejadian yang dianggap penting justru sering muncul sebagai kelas minoritas [38]. Akibat ketidakseimbangan tersebut, model klasifikasi cenderung lebih mudah mempelajari pola kelas mayoritas dan mengabaikan karakteristik kelas minoritas. Dampaknya, model dapat terlihat memiliki performa tinggi secara umum, tetapi sebenarnya gagal mengenali kejadian minoritas yang justru menjadi fokus utama analisis [38].

Salah satu pendekatan yang banyak digunakan untuk mengatasi masalah tersebut adalah *cost-sensitive learning*, yaitu pendekatan yang memberikan bobot atau biaya kesalahan yang berbeda pada tiap kelas [39]. Dalam kerangka ini, kesalahan dalam memprediksi kelas minoritas biasanya diberi biaya lebih besar dibandingkan kesalahan pada kelas mayoritas, sehingga model terdorong untuk lebih memperhatikan observasi yang jarang muncul [39]. Pendekatan ini penting karena pada banyak aplikasi, termasuk deteksi risiko dan anomali, *false negative* sering lebih merugikan daripada *false positive*, sehingga proses pembelajaran perlu mempertimbangkan ketidaksimetrian biaya kesalahan tersebut [39].

Selain melalui pembobotan biaya, penanganan *data imbalance* juga dapat dilakukan melalui *threshold adjustment*, yaitu penyesuaian ambang keputusan klasifikasi agar lebih sesuai dengan distribusi kelas dan tujuan evaluasi [39]. Dalam kondisi tidak seimbang, penggunaan ambang standar sering kali menghasilkan keputusan yang terlalu berpihak pada kelas mayoritas. Oleh karena itu, ambang keputusan dapat digeser untuk meningkatkan sensitivitas terhadap kelas minoritas, meskipun hal ini biasanya disertai *trade-off* terhadap jumlah *false positive* [39]. Penyesuaian ambang ini menjadi relevan karena hasil probabilitas atau skor keluaran model tidak selalu optimal jika langsung diterjemahkan dengan aturan keputusan yang kaku.

Dengan demikian, penanganan *data imbalance* tidak hanya berkaitan dengan distribusi kelas yang tidak merata, tetapi juga dengan bagaimana model dilatih dan bagaimana keputusan akhir ditetapkan [38], [39]. *Cost-sensitive learning* membantu

model belajar dengan mempertimbangkan perbedaan biaya kesalahan, sedangkan *threshold adjustment* membantu menyeimbangkan sensitivitas dan spesifisitas sesuai tujuan penggunaan model [39]. Dalam penelitian ini, pemahaman terhadap masalah *imbalance* menjadi penting karena deteksi risiko dan anomali umumnya berhadapan dengan kejadian minoritas, sehingga strategi pembelajaran dan penentuan ambang perlu dirancang secara lebih hati-hati agar model tidak bias terhadap pola mayoritas.

BAB III

METODOLOGI

3.1. Jenis Penelitian

Penelitian ini merupakan penelitian kuantitatif berbasis data dengan desain eksperimental komputasional. Pendekatan kuantitatif digunakan karena penelitian ini mengolah data numerik dari beberapa domain risiko secara sistematis untuk menghasilkan skor risiko dan keputusan deteksi, sedangkan desain eksperimental komputasional ditunjukkan melalui perancangan model, pelatihan, pengujian, dan evaluasi kinerja secara terstruktur menggunakan data historis.

Penelitian ini diposisikan sebagai *model development and evaluation*, yaitu penelitian yang menempatkan model *machine learning* sebagai objek utama yang dikembangkan dan dianalisis kinerjanya. Dengan posisi ini, penelitian tidak diarahkan pada rekayasa sistem informasi atau pembangunan aplikasi operasional, melainkan pada pembangunan dan pengujian model untuk mendeteksi risiko multi-domain pada rantai pasok pertanian.

Pendekatan yang digunakan bersifat *data-driven modeling*, yaitu pemodelan yang dibangun berdasarkan pola yang dipelajari dari data historis multi-domain pada rantai pasok pertanian, bukan dari aturan pakar yang ditetapkan secara tetap. Data yang digunakan merupakan data sekunder periode 2022–2024 pada wilayah Kabupaten Sumedang, sehingga proses pemodelan dilakukan tanpa pengumpulan data primer melalui survei, wawancara, atau observasi lapangan.

Desain penelitian disusun dalam bentuk *comparative analysis* terhadap tiga model deteksi risiko, yaitu Isolation Forest, Bayesian Network, dan model hybrid Isolation Forest–Bayesian Network. Perbandingan dilakukan untuk mengukur kinerja setiap model dalam menghasilkan skor risiko dan keputusan deteksi, sehingga dapat dianalisis sejauh mana integrasi kedua pendekatan memberikan peningkatan dibandingkan penggunaan model tunggal.

3.2. Metode Pengembangan Model

Metode pengembangan model dalam penelitian ini disusun sebagai *pipeline* yang terdiri atas enam fase, mulai dari pengumpulan data hingga evaluasi kinerja. *Pipeline* ini dirancang agar setiap fase menghasilkan keluaran yang dapat digunakan sebagai masukan pada fase berikutnya, sehingga proses pengembangan model berjalan secara berurutan dan dapat ditelusuri pada setiap tahapnya. Alur *pipeline* secara umum ditunjukkan pada Gambar 3.1.



Gambar 3.1 *Pipeline* Pengembangan Model

- a) *Data Acquisition*. Fase ini mencakup pengumpulan data sekunder dari instansi yang berwenang untuk seluruh domain risiko yang dianalisis, yaitu harga, cuaca, organisme pengganggu tanaman (OPT), distribusi, tindakan pengelolaan, dan produksi. Data yang digunakan merupakan data historis pada wilayah Kabupaten Sumedang periode 2022–2024.
- b) *Data Preprocessing*. Fase ini mencakup integrasi data dari berbagai domain ke dalam struktur yang konsisten, pembersihan data, penyesuaian format atribut waktu, penanganan nilai yang tidak sesuai, serta penyelarasan resolusi temporal antar domain ke unit analisis penelitian. Tujuan utama fase ini adalah memastikan data dari setiap domain berada dalam kondisi yang layak dan seragam untuk diproses pada fase berikutnya.
- c) *Feature Engineering*. Fase ini mencakup pembentukan fitur turunan dari data hasil *preprocessing* serta pembentukan label risiko yang digunakan sebagai target dalam proses pemodelan. Fitur turunan dibentuk untuk merepresentasikan pola risiko pada masing-masing domain, sedangkan label risiko dibentuk melalui pendekatan statistik untuk domain non-cuaca dan pendekatan berbasis aturan untuk domain cuaca.

- d) *Model Development*. Fase ini mencakup pengembangan dua model dasar secara per-domain, yaitu model *Isolation Forest* dan model *Bayesian Network*. *Isolation Forest* dikembangkan untuk menghasilkan skor anomali berdasarkan pola penyimpangan data, sedangkan *Bayesian Network* dikembangkan untuk menghasilkan probabilitas risiko berdasarkan hubungan antara label dan fitur observasi.
- e) *Model Integration (Hybrid)*. Fase ini mencakup pengembangan model *hybrid Isolation Forest–Bayesian Network* melalui *feature-level fusion*, yaitu integrasi pada tingkat fitur dengan menggunakan skor anomali *Isolation Forest* sebagai salah satu masukan bagi *Bayesian Network*. Model *hybrid* menghasilkan probabilitas risiko yang memuat informasi penyimpangan distribusional sekaligus penalaran probabilistik.
- f) *Evaluation*. Fase ini mencakup penentuan *threshold* keputusan deteksi serta evaluasi kinerja ketiga model, yaitu *Isolation Forest*, *Bayesian Network*, dan model *hybrid Isolation Forest–Bayesian Network*. Evaluasi dilakukan dengan membandingkan keluaran model terhadap label risiko yang telah dibentuk pada fase sebelumnya, baik secara keseluruhan maupun secara per-domain.

3.3. Objek Penelitian

Objek dalam penelitian ini adalah deteksi risiko multi-domain pada rantai pasok pertanian yang direpresentasikan melalui data historis pada enam domain risiko, yaitu harga, cuaca, organisme pengganggu tanaman (OPT), distribusi, tindakan pengelolaan, dan produksi. Penelitian berfokus pada pengembangan model untuk mendeteksi penyimpangan signifikan pada indikator-indikator yang berkaitan dengan keenam domain tersebut. Risiko dalam penelitian ini tidak dipahami sebagai kerugian aktual yang telah terjadi, melainkan sebagai kondisi penyimpangan pada indikator domain yang dapat berfungsi sebagai sinyal awal potensi gangguan dalam rantai pasok pertanian.

Penelitian ini menggunakan data dengan cakupan wilayah Kabupaten Sumedang dan periode waktu 2022–2024. Setiap domain memiliki karakteristik data, entitas, dan indikator yang berbeda, sehingga keenam domain tersebut diposisikan sebagai *sub-system* dalam sistem rantai pasok pertanian yang lebih besar. Pemodelan tidak dilakukan dalam satu struktur tunggal yang menggabungkan seluruh domain, melainkan secara per-domain

agar karakteristik data masing-masing tetap terjaga. Meskipun pemodelan dilakukan secara terpisah, antar domain tetap memiliki relasi konseptual yang saling memengaruhi.

3.3.1. Domain Risiko Penelitian

Domain risiko dalam penelitian ini diposisikan sebagai *sub-system* yang masing-masing memiliki definisi operasional, variabel pengamatan, dan peran yang berbeda dalam rantai pasok pertanian. Antar *sub-system* tersebut terdapat relasi konseptual yang saling memengaruhi, sehingga gangguan pada satu domain berpotensi merambat ke domain lain. Penjelasan masing-masing domain diuraikan sebagai berikut.

a) Domain Harga

Domain harga merupakan *sub-system* yang merepresentasikan dinamika harga komoditas pertanian pada pasar tertentu di wilayah Kabupaten Sumedang. Secara operasional, risiko pada domain ini didefinisikan sebagai kondisi penyimpangan signifikan pada nilai harga komoditas dibandingkan pola harga normalnya. Penyimpangan tersebut dapat berupa lonjakan harga maupun penurunan harga yang tidak wajar pada periode tertentu.

Variabel utama pada domain ini adalah nilai harga komoditas pada satuan rupiah per kilogram, dengan entitas pengamatan berupa kombinasi tanggal, pasar, komoditas, dan saluran harga. Variabel-variabel ini memungkinkan dinamika harga dianalisis pada level yang lebih spesifik dibandingkan harga pasar secara umum.

Dalam rantai pasok pertanian, domain harga memiliki relasi konseptual dengan domain produksi dan domain distribusi. Penurunan produksi pada wilayah tertentu berpotensi memengaruhi harga di pasar terkait, sedangkan gangguan distribusi antar pasar dapat menyebabkan perbedaan harga yang signifikan. Sebaliknya, perubahan harga juga dapat memengaruhi pola arus distribusi komoditas antar pasar.

b) Domain Cuaca

Domain cuaca merupakan *sub-system* yang merepresentasikan kondisi meteorologis yang berpotensi mempengaruhi aktivitas budidaya dan rantai pasok pertanian di wilayah Kabupaten Sumedang. Secara operasional, risiko pada domain ini didefinisikan sebagai kondisi cuaca ekstrem yang menyimpang dari pola musimannya, seperti curah hujan sangat tinggi, suhu ekstrem, maupun periode kering yang panjang.

Variabel utama pada domain ini meliputi suhu minimum, suhu maksimum, suhu rata-rata, kelembapan rata-rata, curah hujan, lama penyinaran matahari, serta variabel kecepatan dan arah angin. Berbeda dengan domain lain yang memiliki entitas pada level kecamatan, domain cuaca diposisikan sebagai data pada tingkat wilayah Kabupaten Sumedang secara keseluruhan. Hal ini disebabkan data cuaca yang digunakan berasal dari satu sumber observasi resmi yang mencakup wilayah Sumedang, sehingga belum tersedia variasi pengukuran pada level kecamatan. Konsekuensinya, kondisi cuaca pada minggu yang sama berlaku sebagai *common factor* bagi seluruh kecamatan dalam wilayah Sumedang.

Dalam rantai pasok pertanian, domain cuaca memiliki relasi konseptual yang luas dengan domain lain. Anomali cuaca seperti curah hujan tinggi atau suhu ekstrem berpotensi memicu peningkatan kejadian OPT, sedangkan kondisi cuaca yang tidak mendukung dapat berdampak langsung pada hasil produksi pertanian. Karakteristik ini menempatkan domain cuaca sebagai salah satu *sub-system* yang memengaruhi banyak domain lain pada rantai pasok pertanian.

c) Domain Organisme Pengganggu Tanaman (OPT)

Domain OPT merupakan *sub-system* yang merepresentasikan kondisi gangguan biologis pada komoditas pertanian di wilayah Kabupaten Sumedang. Secara operasional, risiko pada domain ini didefinisikan sebagai kondisi peningkatan kejadian OPT yang menyimpang dari pola normalnya, termasuk kondisi ketika nilai kejadian melampaui ambang ekonomi yang telah ditetapkan untuk komoditas dan jenis OPT tertentu.

Variabel utama pada domain ini meliputi nilai kejadian OPT, ambang ekonomi sebagai nilai acuan pemantauan, serta status melampaui ambang sebagai indikator yang menunjukkan tingkat keparahan kejadian. Entitas pengamatan berupa

kombinasi tanggal, kecamatan, komoditas, dan jenis OPT, sehingga pola kejadian OPT dapat dianalisis pada level yang spesifik untuk setiap kombinasi tersebut.

Dalam rantai pasok pertanian, domain OPT memiliki relasi konseptual yang erat dengan beberapa domain lain. Domain ini menerima pengaruh dari domain cuaca, karena anomali curah hujan, suhu, dan kelembapan dapat memicu peningkatan kejadian OPT. Selain itu, domain OPT memiliki relasi dua arah dengan domain tindakan pengelolaan, yaitu lonjakan kejadian OPT memicu peningkatan tindakan pengendalian, sedangkan tindakan pengelolaan yang efektif berkontribusi pada penurunan kejadian OPT pada periode berikutnya. Pada akhirnya, domain OPT juga memengaruhi domain produksi, karena serangan OPT yang tidak terkendali berpotensi menurunkan hasil panen

d) Domain Distribusi

Domain distribusi merupakan *sub-system* yang merepresentasikan aliran komoditas pertanian antar pasar di wilayah Kabupaten Sumedang. Secara operasional, risiko pada domain ini didefinisikan sebagai kondisi penyimpangan signifikan pada pola arus barang antar pasar, terutama berupa penurunan volume aliran yang dapat mengindikasikan adanya gangguan dalam proses distribusi.

Variabel utama pada domain ini meliputi volume aliran komoditas, harga pada pasar asal, harga pada pasar tujuan, biaya distribusi, dan waktu tempuh distribusi. Entitas pengamatan berupa kombinasi tanggal aliran, pasar asal, pasar tujuan, komoditas, dan saluran distribusi. Dengan struktur entitas tersebut, pola aliran komoditas dapat dianalisis pada level yang lebih spesifik untuk setiap pasangan pasar dan komoditas.

Dalam rantai pasok pertanian, domain distribusi memiliki relasi dua arah dengan domain harga. Perubahan harga pada pasar asal maupun pasar tujuan dapat memengaruhi pola arus distribusi komoditas, sedangkan gangguan pada distribusi berpotensi menyebabkan ketimpangan harga antar pasar. Karakteristik ini menempatkan domain distribusi sebagai *sub-system* yang menjadi penghubung antar pasar pada rantai pasok pertanian, sekaligus sebagai titik yang rentan terhadap akumulasi risiko dari domain lain.

e) Domain Tindakan Pengelolaan

Domain tindakan pengelolaan merupakan *sub-system* yang merepresentasikan respons atau intervensi terhadap kejadian OPT pada komoditas pertanian di wilayah Kabupaten Sumedang. Secara operasional, risiko pada domain ini didefinisikan sebagai kondisi penyimpangan signifikan pada pola tindakan pengelolaan, baik berupa peningkatan intensitas tindakan yang tidak biasa maupun pola respons yang tidak sesuai dengan kondisi normal pengelolaan.

Variabel utama pada domain ini meliputi luas area yang ditangani, dosis atau intensitas tindakan, biaya total pengelolaan, jam kerja yang digunakan, metode pengelolaan yang diterapkan, serta nilai kejadian OPT setelah tindak lanjut sebagai indikator hasil tindakan. Entitas pengamatan berupa kombinasi tanggal tindakan, kecamatan, komoditas, jenis OPT, dan metode pengelolaan, sehingga pola intervensi dapat dianalisis pada level yang spesifik untuk setiap kombinasi tersebut.

Dalam rantai pasok pertanian, domain tindakan pengelolaan memiliki relasi dua arah dengan domain OPT. Lonjakan kejadian OPT memicu peningkatan tindakan pengendalian, sedangkan tindakan yang efektif berkontribusi pada penurunan kejadian OPT pada periode berikutnya. Selain itu, domain tindakan pengelolaan juga memiliki relasi konseptual dengan domain produksi secara tidak langsung, karena tindakan pengendalian yang berhasil membantu mempertahankan hasil panen melalui pengendalian kejadian OPT. Karakteristik ini menempatkan domain tindakan pengelolaan sebagai *sub-system* yang berperan sebagai mekanisme respons sekaligus pelindung hasil produksi pada rantai pasok pertanian.

f) Domain Produksi

Domain produksi merupakan *sub-system* yang merepresentasikan hasil aktivitas budidaya pertanian di wilayah Kabupaten Sumedang. Secara operasional, risiko pada domain ini didefinisikan sebagai kondisi penyimpangan signifikan pada indikator produksi pertanian, terutama berupa penurunan luas panen, total produksi, atau produktivitas yang tidak wajar dibandingkan pola produksi normalnya.

Variabel utama pada domain ini meliputi luas panen dalam satuan hektar, total produksi dalam satuan ton, dan produktivitas dalam satuan ton per hektar. Entitas pengamatan berupa kombinasi bulan, kecamatan, dan komoditas. Karena resolusi data produksi bersifat bulanan, domain ini memiliki karakteristik temporal yang berbeda dengan domain lain yang umumnya tersedia pada resolusi yang lebih halus. Konsekuensi dari karakteristik ini adalah perlunya penyesuaian resolusi temporal pada tahap *preprocessing* agar data produksi dapat dianalisis bersama domain lain pada unit analisis yang seragam.

Dalam rantai pasok pertanian, domain produksi memiliki posisi sebagai *sub-system* yang menerima dampak dari beberapa domain sebelumnya sekaligus memengaruhi domain berikutnya. Domain produksi menerima pengaruh dari domain cuaca, karena kondisi meteorologis ekstrem dapat menurunkan hasil panen, dan dari domain OPT, karena serangan OPT yang tidak terkendali berdampak langsung pada produksi. Domain produksi juga menerima pengaruh tidak langsung dari domain tindakan pengelolaan melalui mekanisme pengendalian OPT. Pada akhirnya, domain produksi memengaruhi domain harga, karena penurunan hasil produksi pada wilayah tertentu dapat memicu kenaikan harga pada pasar terkait. Posisi ini menempatkan domain produksi sebagai *sub-system* yang menjadi titik akumulasi dampak risiko dari domain biofisik, sekaligus titik awal pengaruh terhadap domain ekonomi pada rantai pasok pertanian.

3.3.2. Entitas, Variabel, Satuan, dan Sumber Data

Subbab ini menjelaskan entitas pengamatan, variabel, satuan pengukuran, dan sumber data yang digunakan pada masing-masing domain penelitian. Penjelasan ini bertujuan untuk memperjelas struktur data yang menjadi dasar dalam proses analisis dan pemodelan. Ringkasan teknis mengenai entitas, variabel, satuan, dan sumber data disajikan pada Tabel 3.1.

Tabel 3.1 Variabel, Satuan, dan Sumber Data per Domain

Domain	Variabel	Satuan	Sumber Data
Harga	price_value	Rp/kg	Dinas Pertanian Kabupaten Sumedang
	price_channel_code	Kategorikal (WHOLESALE_TRAD, RETAIL_TRAD, RETAIL_MODERN)	Dinas Pertanian Kabupaten Sumedang
Cuaca	TN	°C (suhu minimum)	BMKG
	TX	°C (suhu maksimum)	BMKG
	TAVG	°C (suhu rata-rata)	BMKG
	RH_AVG	% (kelembapan rata-rata)	BMKG
	RR	mm (curah hujan)	BMKG
	SS	jam (lama penyinaran matahari)	BMKG
	FF_X	m/s (kecepatan angin maksimum)	BMKG
	FF_AVG	m/s (kecepatan angin rata-rata)	BMKG
	DDD_X	derajat (arah angin saat kecepatan maksimum)	BMKG
	DDD_CAR	Kategorikal (arah angin terbanyak)	BMKG

Tabel 3.1 (lanjutan)

Domain	Variabel	Satuan	Sumber Data
OPT	incidence_value	bervariasi per jenis OPT (ekor/rumpun, % insidensi, % keparahan)	Dinas Pertanian Kabupaten Sumedang
	ae_value	bervariasi per jenis OPT (sesuai satuan kejadian)	Dinas Pertanian Kabupaten Sumedang
	over_ae	Boolean (status melampaui ambang ekonomi)	Dinas Pertanian Kabupaten Sumedang
Distribusi	flow_volume	ton	Dinas Pertanian Kabupaten Sumedang
	price_origin	Rp/kg (harga pasar asal)	Dinas Pertanian Kabupaten Sumedang
	price_dest	Rp/kg (harga pasar tujuan)	Dinas Pertanian Kabupaten Sumedang
	transport_cost	Rp per transaksi	Dinas Pertanian Kabupaten Sumedang
	handling_cost	Rp per transaksi	Dinas Pertanian Kabupaten Sumedang
	other_cost	Rp per transaksi	Dinas Pertanian Kabupaten Sumedang
	lead_time_days	hari (waktu tempuh distribusi)	Dinas Pertanian Kabupaten Sumedang
	channel_name	Kategorikal (Eceran, Grosir)	Dinas Pertanian Kabupaten Sumedang
	intermediary_type	Kategorikal (Agen, Koperasi, Pedagang Pengumpul)	Dinas Pertanian Kabupaten Sumedang
Tindakan Pengelolaan	incidence_value	bervariasi per metode pemantauan	Dinas Pertanian Kabupaten Sumedang
	incidence_value_followup	bervariasi per metode pemantauan	Dinas Pertanian Kabupaten Sumedang
	ae_value	bervariasi per jenis OPT	Dinas Pertanian Kabupaten Sumedang
	over_ae	Boolean (status melampaui ambang ekonomi)	Dinas Pertanian Kabupaten Sumedang

Tabel 3.1 (lanjutan)

Domain	Variabel	Satuan	Sumber Data
Tindakan Pengelolaan	trigger_type	Kategorikal (AE)	Dinas Pertanian Kabupaten Sumedang
	management_method_name	Kategorikal (Kimia)	Dinas Pertanian Kabupaten Sumedang
	area_treated	hektar	Dinas Pertanian Kabupaten Sumedang
	dose_or_intensity	bervariasi sesuai metode pengelolaan	Dinas Pertanian Kabupaten Sumedang
	cost_total	Rp per kejadian	Dinas Pertanian Kabupaten Sumedang
	labor_hours	jam	Dinas Pertanian Kabupaten Sumedang
Produksi	harvest_area_ha	hektar (luas panen)	Dinas Pertanian Kabupaten Sumedang
	production_ton	ton (total produksi)	Dinas Pertanian Kabupaten Sumedang
	yield_ton_per_ha	ton/hektar (produktivitas)	Dinas Pertanian Kabupaten Sumedang

3.3.3. Unit Analisis Penelitian

Unit analisis dalam penelitian ini adalah observasi mingguan pada level kecamatan untuk setiap domain risiko. Dengan demikian, satu pengamatan dalam pemodelan merepresentasikan kondisi suatu domain risiko pada satu kecamatan dalam satu minggu tertentu. Penetapan unit analisis pada level kecamatan dan resolusi mingguan diarahkan untuk menjamin konsistensi pemodelan, sehingga kinerja deteksi dapat diperbandingkan secara setara antar domain dan antar wilayah.

3.4. Teknik Pengumpulan Data

Penelitian ini menggunakan data sekunder berupa arsip historis yang diperoleh secara resmi dari instansi yang berwenang, bukan data primer yang dikumpulkan langsung melalui survei, wawancara, atau observasi lapangan. Pendekatan ini dipilih karena data operasional pada masing-masing domain risiko telah tersedia dalam bentuk catatan historis di instansi terkait, sehingga proses pengumpulan data dilakukan melalui akuisisi arsip dan studi dokumen.

Data pada domain cuaca diperoleh dari Badan Meteorologi, Klimatologi, dan Geofisika (BMKG) Stasiun Klimatologi Bandung yang mencakup wilayah Kabupaten Sumedang. Sementara itu, data pada domain harga, organisme pengganggu tanaman (OPT), distribusi, tindakan pengelolaan, dan produksi diperoleh dari Dinas Pertanian Kabupaten Sumedang dengan pendampingan langsung dari dosen pembimbing. Seluruh data yang digunakan mencakup periode 2022–2024 dan diterima dalam bentuk arsip digital sebagai masukan pada tahapan pemrosesan data penelitian.

Validasi data dilakukan melalui tiga lapisan pemeriksaan untuk memastikan data yang diterima layak digunakan sebagai bahan pemodelan:

- a) Validasi sumber, yaitu memastikan bahwa data berasal dari instansi resmi yang memiliki otoritas dan rekam jejak pencatatan yang terstandarisasi pada bidangnya.
- b) Validasi struktural, yaitu pemeriksaan kelengkapan kolom, konsistensi format atribut waktu, ketersediaan nilai pada periode 2022–2024, dan keberadaan kolom identitas entitas yang dibutuhkan untuk pemodelan.
- c) Validasi nilai, yaitu pemeriksaan terhadap keberadaan nilai yang tidak masuk akal pada pengukuran masing-masing domain.

3.5. Teknik Analisis Data

Teknik analisis data dalam penelitian ini dilakukan melalui serangkaian tahapan yang dirancang untuk membangun dan mengevaluasi model deteksi risiko multi-domain pada rantai pasok pertanian. Tahapan tersebut meliputi pembentukan label risiko, pra-pemrosesan data dan feature engineering, pengembangan model *Isolation Forest*, pengembangan model *Bayesian Network*, pengembangan model hybrid *Isolation Forest–Bayesian Network*, penentuan threshold, serta evaluasi model. Seluruh tahapan analisis disusun secara berurutan agar keluaran dari setiap tahap dapat digunakan sebagai masukan pada tahap berikutnya.

3.5.1. Pembentukan Label Risiko

Pembentukan label risiko dilakukan untuk menghasilkan target yang digunakan dalam pelatihan dan evaluasi model. Label utama yang digunakan dalam penelitian ini adalah label biner *label_is_anomaly* yang menunjukkan apakah suatu observasi tergolong anomali atau tidak, sedangkan label kategori *label_severity* digunakan untuk menunjukkan tingkat keparahan anomali pada tiga kategori, yaitu Normal, Waspada, dan Bahaya. Pelatihan dan evaluasi model berfokus pada label biner, sementara label kategori digunakan sebagai informasi pendukung untuk keperluan interpretasi hasil.

a) Pembentukan Label Pada Domain Non – Cuaca

Untuk domain non-cuaca, yaitu harga, OPT, distribusi, tindakan pengelolaan, dan produksi, label anomali dibentuk menggunakan pendekatan deviasi *robust* berbasis *Median Absolute Deviation* (MAD). Pendekatan ini dipilih karena lebih tahan terhadap nilai ekstrem dibandingkan pendekatan berbasis simpangan baku, sehingga lebih sesuai untuk data operasional pertanian yang sering mengandung nilai ekstrem alami. Nilai deviasi *robust* untuk setiap observasi dihitung menggunakan rumus berikut:

$$AE_{dev} = \frac{|x - \text{median}(x)|}{MAD}$$

dengan :

$$MAD = \text{median}(|x - \text{median}(x)|)$$

Pada kondisi ketika nilai MAD bernilai nol, simpangan baku digunakan sebagai pengganti, dan apabila simpangan baku juga bernilai nol, penyebut ditetapkan pada nilai konstan yang sangat kecil agar perhitungan tetap dapat dilakukan.

Setelah nilai deviasi diperoleh, ditentukan ambang anomali per kelompok menggunakan kuantil 0,975 dari distribusi *AEdev* dalam kelompok tersebut. Kelompok dibentuk berdasarkan kombinasi kolom identitas yang tersedia, seperti *risk_name*, *market_id*, *commodity_id*, dan *district_id*. Apabila jumlah data dalam suatu kelompok kurang dari 200 baris, digunakan ambang global yang dihitung dari seluruh data domain. Suatu observasi diberi label anomali (*label_is_anomaly* = 1) apabila nilai deviasinya melebihi ambang yang berlaku pada kelompoknya, dan label normal (*label_is_anomaly* = 0) apabila tidak.

b) Pembentukan Label Pada Domain Cuaca

Berbeda dengan domain non-cuaca, domain cuaca menggunakan pendekatan berbasis aturan (*rule-based*). Pendekatan ini dipilih karena variabel cuaca memiliki pola musiman yang kuat, sehingga penyimpangan yang relevan secara agronomis lebih sesuai didefinisikan melalui aturan yang merepresentasikan kondisi cuaca ekstrem. Tiga aturan utama digunakan dalam penelitian ini, yaitu *ExtremeRain*, *HeatStress*, dan *DrySpell*, dengan ketentuan sebagai berikut:

- (1) *ExtremeRain* aktif apabila curah hujan harian (RR) lebih besar atau sama dengan 50 mm per hari, atau melebihi median musiman ditambah dua kali nilai *interquartile range* (IQR) musiman.
- (2) *HeatStress* aktif apabila suhu rata-rata harian (TAVG) lebih besar atau sama dengan 32 °C, atau melebihi median musiman ditambah dua kali IQR musiman.
- (3) *DrySpell* aktif apabila curah hujan bernilai nol selama sedikitnya tujuh hari berturut-turut.

Suatu observasi cuaca diberi label *label_is_anomaly* = 1 apabila salah satu atau lebih aturan tersebut aktif.

c) Pembentukan Label Pada Domain Cuaca

Setelah label biner terbentuk, observasi yang tergolong anomali ($label_is_anomaly = 1$) diberi kategori tingkat keparahan menggunakan label $label_severity$ dengan tiga kategori:

- (1) Normal, untuk observasi dengan $label_is_anomaly = 0$.
- (2) Waspada, untuk observasi anomali dengan tingkat penyimpangan moderat.
- (3) Bahaya, untuk observasi anomali dengan tingkat penyimpangan tinggi.

Pada domain non-cuaca, batas antara kategori Waspada dan Bahaya ditentukan berdasarkan persentil $AEdev$ pada kelompok yang sama. Pada domain cuaca, kategori Bahaya diberikan apabila dua atau lebih aturan aktif secara bersamaan, sedangkan kategori Waspada diberikan apabila hanya satu aturan yang aktif.

3.5.2. *Preprocessing dan Feature Engineering*

Tahap *preprocessing* dan *feature engineering* dilakukan untuk memastikan bahwa data dari setiap domain berada dalam kondisi yang layak dan seragam sebelum digunakan pada tahap pemodelan, serta untuk membentuk fitur turunan yang dapat menangkap pola risiko pada masing-masing domain. Tahap ini mencakup pembersihan data, *handling missing value*, normalisasi, *temporal alignment* yang meliputi agregasi resolusi halus dan *bridging* resolusi kasar ke unit analisis mingguan, penyelarasan entitas spasial, serta *feature engineering*.

a) Handling Missing Value

Sebelum penanganan *missing value* dilakukan, terlebih dahulu dilakukan standardisasi nilai *missing* dengan mengganti penanda non-standar yang umum digunakan dalam pencatatan instansi seperti tanda hubung "—", angka 8888, dan 9999 menjadi nilai NaN, sehingga dapat ditangani secara konsisten pada tahap berikutnya. Penanganan *missing value* selanjutnya dilakukan dengan strategi yang disesuaikan terhadap karakteristik masing-masing model. Pada model *Isolation Forest*, *missing value* diisi menggunakan median per kelompok identitas sebelum data dimasukkan ke dalam model. Pendekatan median dipilih karena lebih tahan terhadap nilai ekstrem dibandingkan rata-rata, dan konsisten dengan pendekatan *robust* yang diterapkan sepanjang penelitian ini. Pada model *Bayesian Network*, *missing value* ditangani secara implisit pada tahap diskretisasi, sehingga setiap

fitur numerik diubah menjadi kategori diskret tanpa mengharuskan imputasi nilai eksplisit. Untuk baris data yang tidak memiliki identitas entitas wajib seperti *district_id*, dilakukan penghapusan baris karena entitas tersebut diperlukan untuk pemodelan pada level kecamatan.

b) Normalisasi

Normalisasi dilakukan untuk menyeragamkan skala fitur numerik sebelum digunakan sebagai masukan model. Penelitian ini menggunakan *RobustScaler*, yaitu metode normalisasi berbasis median dan *interquartile range* (IQR), bukan rata-rata dan simpangan baku seperti pada *StandardScaler*. *RobustScaler* dipilih karena lebih tahan terhadap pengaruh nilai ekstrem, sehingga sesuai untuk data deteksi anomali yang justru mengandung observasi ekstrem sebagai target deteksi.

Selain normalisasi fitur masukan, skor anomali dari *Isolation Forest* juga dinormalisasi ke rentang 0 hingga 1 untuk memudahkan integrasi dengan komponen *Bayesian Network* pada tahap *feature-level fusion*. Fitur kategorikal tidak dimasukkan sebagai input langsung pada model *Isolation Forest*, dan untuk model *Bayesian Network*, fitur numerik diubah menjadi bentuk diskret melalui pendekatan *quantile-based binning* yang akan dijelaskan pada Subbab 3.5.4

c) *Temporal Alignment*

Temporal alignment dilakukan untuk menyelaraskan data dari berbagai domain ke unit analisis mingguan sebagaimana ditetapkan pada Subbab 3.3.3. Karena data asli memiliki resolusi yang berbeda-beda antar domain, *temporal alignment* mencakup dua arah penyelarasan: agregasi dari resolusi lebih halus ke mingguan, dan *bridging* dari resolusi lebih kasar ke mingguan. Strategi penyelarasan per domain dirangkum pada Tabel 3.2.

Tabel 3.2 Strategi *Temporal Alignment* per Domain

Domain	Resolusi Asli	Strategi	Detail
Harga	Harian	Agregasi → mingguan	Rata-rata price_value per minggu
Cuaca	Harian	Agregasi → mingguan	Curah hujan (RR) dijumlah; variabel suhu, kelembapan, penyinaran, dan angin dirata-ratakan per minggu
OPT	Mingguan	-	Pemastian indeks minggu (week_start) konsisten
Distribusi	Per transaksi	Agregasi → mingguan	Total flow_volume, jumlah transaksi, rata-rata harga dan biaya per minggu
Tindakan Pengelolaan	Per kejadian	Agregasi → mingguan	Jumlah kejadian, total area_treated, total cost_total, total labor_hours per minggu
Produksi	Bulanan	Bridging → mingguan	Nilai bulanan di-broadcast ke seluruh minggu dalam bulan tersebut

d) Feature Engineering

Setelah data diselaraskan ke unit analisis mingguan, dilakukan *feature engineering* untuk membentuk fitur turunan yang dapat menangkap pola risiko pada masing-masing domain. Fitur dikelompokkan ke dalam beberapa kategori, yaitu fitur dasar yang berasal langsung dari variabel domain, fitur *lag* untuk menangkap temporal jangka pendek dan menengah, fitur *rolling* untuk menangkap tren dan variabilitas dalam jendela waktu bergerak, fitur tanggal untuk musim, serta fitur lintas-domain berupa variabel cuaca yang dimasukkan ke domain OPT, tindakan pengelolaan, dan produksi sesuai relasi konseptual yang telah dijelaskan pada Subbab 3.3.1. Fitur kategorikal seperti saluran harga, metode pemantauan, dan saluran distribusi diubah ke representasi numerik melalui *label encoding* agar dapat digunakan sebagai masukan model.

Untuk menghindari kebocoran informasi (*data leakage*) antara fitur dan label, skor *Anomaly Evidence* yang digunakan pada pembentukan label di Subbab 3.5.1 tidak digunakan sebagai fitur masukan model. Fitur masukan dibentuk dari variabel mentah dan turunan temporalnya, sehingga model belajar mengenali pola anomali dari data observasi, bukan dari sinyal yang sudah dipakai untuk membentuk label. Pemisahan ini penting untuk menjaga validitas evaluasi model.

3.5.3. Pengembangan Model *Isolation Forest*

Pengembangan model *Isolation Forest* dilakukan untuk menghasilkan komponen deteksi anomali berbasis *unsupervised learning* pada setiap domain risiko. *Isolation Forest* dipilih karena mampu mengenali penyimpangan pada data multivariat melalui mekanisme isolasi acak tanpa memerlukan label pada tahap pelatihan, serta relatif efisien untuk diterapkan pada domain risiko dengan karakteristik distribusi yang berbeda-beda [33], [34]. Pemodelan dilakukan secara per-domain, sehingga setiap domain memiliki model *Isolation Forest* tersendiri yang dilatih pada data hasil *feature engineering* sebagaimana dijelaskan pada Subbab 3.5.2.

a) Parameter Model

Konfigurasi parameter model *Isolation Forest* yang digunakan pada penelitian ini meliputi *n_estimators*, *contamination*, *max_samples*, dan *random_state*. Parameter *n_estimators* menentukan jumlah pohon isolasi yang dibangun dalam *ensemble*, sedangkan *contamination* menentukan proporsi anomali yang diasumsikan terdapat dalam data dan berpengaruh langsung pada ambang keputusan model. Parameter *max_samples* menentukan ukuran subsampel yang digunakan untuk membangun setiap pohon, dan *random_state* digunakan untuk menjaga konsistensi hasil pelatihan pada setiap eksekusi.

Berdasarkan praktik umum pemodelan *Isolation Forest* dan pertimbangan karakteristik data penelitian, kandidat awal parameter yang akan digunakan sebagai titik mula *tuning* adalah *n_estimators* = 300, *contamination* = 0,02, *max_samples* = “*auto*”, dan *random_state* = 42. Pemilihan *n_estimators* lebih besar dari nilai *default* 100 ditujukan untuk meningkatkan kestabilan skor anomali, sedangkan *contamination* = 0,02 ditetapkan dengan asumsi proporsi anomali yang relatif rendah pada data operasional pertanian. Nilai *max_samples* = “*auto*”

membuat ukuran subsampel mengikuti ketentuan minimum antara 256 dan jumlah observasi tersedia, sehingga model tetap efisien meskipun ukuran data berbeda antar domain.

b) Strategi Tuning Parameter

Karena performa *Isolation Forest* sensitif terhadap konfigurasi parameter, terutama *contamination* [17], [18] penelitian ini menerapkan strategi *tuning* untuk memperoleh konfigurasi yang sesuai dengan karakteristik data setiap *domain*. *Tuning* dilakukan dengan pendekatan eksplorasi terbatas pada parameter utama, yaitu *n_estimators* dan *contamination*, dengan mempertimbangkan kestabilan skor anomali dan kecocokan terhadap *label* operasional yang telah dibentuk pada Subbab 3.5.1.

Untuk parameter *n_estimators*, dieksplorasi beberapa nilai dalam rentang yang umum digunakan untuk memastikan stabilitas skor tidak terlalu sensitif terhadap jumlah pohon. Untuk parameter *contamination*, dilakukan penyesuaian secara adaptif berdasarkan proporsi *label* positif pada data latih per *domain*, sehingga nilai *contamination* setiap *domain* dapat berbeda mengikuti karakteristik distribusi anomali masing-masing. Hasil *tuning* dievaluasi menggunakan metrik kinerja yang dijelaskan pada Subbab 3.5.7, dengan pembagian data berbasis waktu untuk menghindari kebocoran informasi dari data uji ke proses pelatihan.

c) Output Model

Keluaran utama model *Isolation Forest* berupa skor anomali yang merepresentasikan tingkat penyimpangan suatu observasi terhadap pola data normal. Skor mentah yang dihasilkan oleh fungsi *scoring* model terlebih dahulu dinormalisasi agar nilai yang lebih tinggi merepresentasikan tingkat anomali yang lebih tinggi, kemudian dinormalisasi ke rentang 0 hingga 1 menggunakan *MinMaxScaler*. Normalisasi ini dilakukan agar skor lebih mudah diperbandingkan antar observasi dalam *domain* yang sama, serta dapat digunakan sebagai masukan pada tahap *feature-level fusion* yang dijelaskan pada Subbab 3.5.5.

Pada tahap ini, *Isolation Forest* berperan sebagai komponen yang menangkap sinyal penyimpangan distribusional pada setiap *domain* risiko. Skor yang dihasilkan tidak langsung diterjemahkan menjadi keputusan deteksi, melainkan diteruskan ke mekanisme *threshold* yang dijelaskan pada Subbab 3.5.6, atau diintegrasikan dengan komponen *Bayesian Network* pada model *hybrid*.

3.5.4. Pengembangan Model *Bayesian Network*

Pengembangan model *Bayesian Network* dilakukan untuk menghasilkan komponen inferensi probabilistik pada setiap domain risiko. *Bayesian Network* dipilih karena mampu merepresentasikan hubungan antara variabel observasi dan label risiko melalui struktur graf probabilistik, serta dapat menghasilkan probabilitas anomali yang lebih informatif dibandingkan keluaran biner [9], [12], [13]. Pemodelan dilakukan secara per-domain agar karakteristik masing-masing domain tetap terjaga, sehingga setiap domain memiliki model *Bayesian Network* tersendiri yang dilatih pada data hasil *feature engineering* sebagaimana dijelaskan pada Subbab 3.5.2.

a) Struktur DAG dan Pendekatan *Naive Bayes*

Struktur graf yang digunakan dalam penelitian ini adalah *Directed Acyclic Graph* (DAG) dengan pendekatan *Naive Bayes*, yaitu struktur sederhana di mana label risiko ditempatkan sebagai *parent node* terhadap seluruh fitur observasi. Struktur DAG yang digunakan dapat dinyatakan sebagai berikut :

$$\text{label}_{\text{is_anomaly}} \rightarrow \text{feature}_1, \text{feature}_2, \dots, \text{feature}_N$$

dengan label `label_is_anomaly` sebagai *parent node* tunggal yang memiliki panah ke seluruh fitur observasi (baik fitur dasar, *lag*, *rolling*, tanggal, lintas-domain, maupun kategorikal). Struktur ini bersifat tetap dan tidak dipelajari secara otomatis melalui *structure learning*, sehingga konsistensi bentuk model dapat dijaga di seluruh domain.

Pemilihan pendekatan *Naive Bayes* dilakukan dengan beberapa pertimbangan. Pertama, pendekatan ini memiliki efisiensi komputasi yang tinggi karena setiap fitur diasumsikan saling bebas bersyarat terhadap label, sehingga estimasi parameter dan inferensi dapat dilakukan dengan cepat meskipun jumlah fitur per domain mencapai sepuluh hingga dua belas variabel. Kedua, pendekatan ini menghindari kebutuhan *structure learning* yang membutuhkan biaya komputasi tinggi dan tidak selalu menghasilkan struktur yang dapat ditafsirkan. Ketiga, struktur *Naive Bayes* telah terbukti efektif untuk klasifikasi probabilistik pada berbagai pemodelan risiko [11], dan cocok untuk kebutuhan penelitian ini yang berfokus pada kemampuan model menghasilkan probabilitas anomali, bukan pada penalaran kausal antar fitur.

b) *Conditional Probability Table (CPT)*

Setiap simpul pada *Bayesian Network* memiliki *Conditional Probability Table* (CPT) yang menyimpan probabilitas nilai simpul tersebut dengan syarat nilai simpul *parent*-nya. Pada struktur Naive Bayes yang digunakan, CPT terbagi menjadi dua jenis. Pertama, CPT untuk simpul label berupa probabilitas *prior* dari masing-masing kelas label (normal dan anomali) yang diestimasi dari distribusi label pada data latih. Kedua, CPT untuk setiap simpul fitur berupa probabilitas kondisional fitur terhadap label, yaitu peluang fitur mengambil nilai diskret tertentu pada kondisi label normal maupun label anomali.

Estimasi parameter CPT dilakukan menggunakan *Bayesian estimator* dengan *prior Bayesian Dirichlet equivalent uniform* (BDeu). Penggunaan *prior* ini bertujuan menjaga kestabilan estimasi probabilitas, terutama pada kombinasi nilai fitur dan label yang jarang muncul di data latih. Tanpa *prior*, kombinasi yang tidak pernah teramati akan menghasilkan probabilitas nol yang dapat menyebabkan inferensi tidak stabil. Dengan *prior* BDeu, probabilitas pada kombinasi tersebut tetap terdefinisi dengan nilai kecil yang masuk akal, sehingga model tetap dapat melakukan inferensi pada data uji yang mengandung kombinasi baru.

c) *Output Model*

Keluaran utama model *Bayesian Network* berupa probabilitas *posterior* anomali, yaitu peluang suatu observasi tergolong anomali dengan syarat nilai fitur-fiturnya. Probabilitas ini diperoleh melalui inferensi probabilistik pada struktur DAG menggunakan aturan Bayes, di mana CPT yang telah diestimasi dari data latih digunakan untuk menghitung peluang label kondisional terhadap kombinasi nilai fitur observasi. Berbeda dengan *Isolation Forest* yang menghasilkan skor anomali berbasis penyimpangan distribusional, *Bayesian Network* menghasilkan ukuran probabilitas yang dapat diinterpretasikan sebagai derajat keyakinan model terhadap status anomali suatu observasi. Probabilitas ini selanjutnya digunakan baik sebagai keluaran model tunggal pada tahap evaluasi, maupun sebagai komponen pada model *hybrid Isolation Forest–Bayesian Network* yang dijelaskan pada Subbab 3.5.5.

3.5.5. Pengembangan Model *Hybrid Isolation Forest–Bayesian Network*

Pengembangan model *hybrid Isolation Forest–Bayesian Network* dilakukan untuk mengintegrasikan dua pendekatan deteksi yang memiliki karakteristik berbeda, yaitu *Isolation Forest* sebagai komponen deteksi anomali berbasis isolasi distribusional, dan *Bayesian Network* sebagai komponen inferensi probabilistik. Integrasi ini ditujukan untuk memanfaatkan kekuatan masing-masing komponen, sehingga model dapat menghasilkan probabilitas risiko yang memuat informasi penyimpangan distribusional sekaligus penalaran probabilistik. Pemodelan dilakukan secara per-domain, sehingga setiap domain memiliki model *hybrid* tersendiri yang dilatih pada data hasil *feature engineering* sebagaimana dijelaskan pada Subbab 3.5.2.


a) Strategi *Feature-Level Fusion*

Penelitian ini menggunakan strategi *feature-level fusion*, yaitu integrasi pada tingkat fitur dengan menjadikan keluaran dari *Isolation Forest* sebagai salah satu masukan bagi *Bayesian Network*. Strategi ini berbeda dengan *score-level fusion* yang menggabungkan keluaran kedua model secara langsung pada tahap akhir, misalnya melalui rata-rata atau penjumlahan skor.

Pemilihan *feature-level fusion* didasarkan pada beberapa pertimbangan. *Pertama*, strategi ini memungkinkan *Bayesian Network* memodelkan hubungan probabilistik antara skor *Isolation Forest* dan label risiko bersama dengan fitur observasi lainnya, sehingga skor anomali tidak diperlakukan sebagai informasi terpisah, melainkan terintegrasi dalam kerangka inferensi probabilistik. *Kedua*, strategi ini menghasilkan satu keluaran tunggal berupa probabilitas *posterior* dari *Bayesian Network*, sehingga tidak menimbulkan ambiguitas yang dapat muncul ketika dua keluaran model paralel memberikan sinyal yang bertentangan. *Ketiga*, strategi ini lebih sesuai dengan kebutuhan penelitian yang menjadikan probabilitas risiko sebagai keluaran operasional model deteksi, bukan sekadar skor agregat.

b) Alur Pengembangan Model *Hybrid*

Alur pengembangan model *hybrid* dilakukan secara sekuensial, dimulai dari pelatihan *Isolation Forest*, dilanjutkan dengan diskretisasi skor anomali, dan diakhiri dengan pelatihan *Bayesian Network* yang memuat skor anomali sebagai salah satu fitur. Alur tersebut diilustrasikan pada Gambar 3.2.



Gambar 3.2 Alur Pengembangan Model Hybrid

Berdasarkan Gambar 3.2, alur pengembangan model *hybrid* dapat dijabarkan dalam empat tahap. *Pertama*, *Isolation Forest* dilatih pada fitur asli domain untuk menghasilkan skor anomali ternormalisasi *if_score_norm* pada rentang 0 hingga 1, sebagaimana dijelaskan pada Subbab 3.5.3. *Kedua*, skor anomali tersebut didiskretkan menjadi *if_score_disc* melalui *quantile-based binning* dengan empat *bin* (Q1, Q2, Q3, dan Q4), konsisten dengan strategi diskretisasi yang diterapkan pada fitur numerik lain. *Ketiga*, *Bayesian Network* dilatih dengan masukan berupa fitur asli domain ditambah *if_score_disc* sebagai fitur tambahan, mengikuti struktur Naive Bayes yang sama seperti yang dijelaskan pada Subbab 3.5.4. *Keempat*, model *hybrid* menghasilkan probabilitas *posterior* risiko sebagai keluaran akhir.

Struktur graf pada model *hybrid* tetap mengikuti pendekatan Naive Bayes dengan label *label_is_anomaly* sebagai *parent node*, namun dengan tambahan *if_score_disc* sebagai salah satu fitur anak. Struktur DAG model *hybrid* dapat dinyatakan sebagai berikut:

$$\text{label}_{\text{is_anomaly}} \rightarrow \text{feature}_1, \text{feature}_2, \dots, \text{feature}_N, \text{if_score_disc}$$

Dengan struktur ini, perbedaan antara model *Bayesian Network* tunggal dan model *hybrid* hanya terletak pada keberadaan *if_score_disc* sebagai fitur tambahan, sehingga perbedaan kinerja pada tahap evaluasi dapat sepenuhnya dikaitkan dengan kontribusi skor *Isolation Forest*. Estimasi parameter *Conditional Probability Table* (CPT) untuk *if_score_disc* dilakukan dengan pendekatan yang sama seperti fitur lain, yaitu menggunakan *Bayesian estimator* dengan *prior Bayesian Dirichlet equivalent uniform* (BDeu)

c) Output Model Hybrid

Keluaran utama model *hybrid* berupa probabilitas *posterior* anomali yang dihasilkan oleh *Bayesian Network* setelah memuat *if_score_disc* sebagai salah satu fitur masukan. Probabilitas ini dapat diinterpretasikan sebagai derajat keyakinan model terhadap status anomali suatu observasi, dengan tambahan informasi penyimpangan distribusional yang ditangkap oleh *Isolation Forest*.

Berbeda dengan model *Isolation Forest* tunggal yang menghasilkan skor berbasis isolasi, dan model *Bayesian Network* tunggal yang hanya memuat fitur observasi domain, model *hybrid* menghasilkan probabilitas yang memuat dua jenis informasi sekaligus, yaitu informasi penyimpangan distribusional dari *Isolation Forest* dan informasi kondisional probabilistik dari *Bayesian Network*. Probabilitas ini menjadi keluaran utama yang akan digunakan pada mekanisme *threshold* keputusan deteksi yang dijelaskan pada Subbab 3.5.6, dan diperbandingkan dengan keluaran model tunggal pada tahap evaluasi yang dijelaskan pada Subbab 3.5.7.

3.5.6. Mekanisme *Threshold* dan Keputusan Deteksi

Mekanisme *threshold* dan keputusan deteksi dilakukan untuk mengubah keluaran model yang berbentuk skor kontinu menjadi keputusan biner anomali atau normal, sekaligus menentukan tingkat keparahan anomali sebagaimana didefinisikan pada Subbab 3.5.1. Mekanisme ini berlaku pada ketiga model yang dikembangkan, yaitu *Isolation Forest*, *Bayesian Network*, dan model *hybrid Isolation Forest–Bayesian Network*, sehingga keluaran ketiga model dapat diperbandingkan dalam kondisi keputusan deteksi yang setara.

a) Penentuan *Threshold Static*

Penelitian ini menggunakan pendekatan ***static threshold***, yaitu nilai ambang yang ditentukan sekali pada tahap pelatihan dan digunakan secara tetap pada tahap pengujian. *Threshold* dihitung secara per-domain, yaitu setiap domain risiko memiliki nilai *threshold* tersendiri yang dihitung dari distribusi skor data latih pada domain tersebut. Pendekatan per-domain dipilih karena distribusi skor anomali pada setiap domain memiliki karakteristik yang berbeda, sehingga *threshold* tunggal yang berlaku seragam untuk seluruh domain dapat menyebabkan model menjadi terlalu sensitif untuk domain tertentu dan terlalu konservatif untuk domain lain.

Nilai *threshold* setiap domain ditetapkan menggunakan kuantil 0,98 dari distribusi skor data latih, yang berarti 2% observasi dengan skor tertinggi diidentifikasi sebagai kandidat anomali. Pemilihan kuantil 0,98 didasarkan pada konsistensi dengan asumsi proporsi anomali rendah pada data operasional pertanian, sebagaimana juga digunakan pada parameter *contamination* = 0,02 model *Isolation Forest* yang dijelaskan pada Subbab 3.5.3. Untuk setiap model dan setiap domain, *threshold* dihitung secara terpisah, sehingga total terdapat *threshold* yang berbeda-beda untuk kombinasi (model, domain) pada penelitian ini.

b) *Pertimbangan Static dan Dynamic Threshold*

Selain *static threshold*, dalam praktik deteksi anomali dikenal pula pendekatan *dynamic threshold*, yaitu *threshold* yang berubah-ubah mengikuti konteks waktu, jendela bergerak, atau perubahan distribusi data. Kedua pendekatan memiliki karakteristik yang berbeda. *Static threshold* menawarkan keunggulan berupa konsistensi keputusan antar observasi, kemudahan reproduksi hasil, dan kemudahan implementasi pada sistem yang akan digunakan secara operasional. Sementara itu, *dynamic threshold* menawarkan adaptabilitas terhadap perubahan distribusi data, sehingga dapat lebih responsif terhadap pola musiman atau pergeseran tren.

Pada penelitian ini, *static threshold* dipilih sebagai pendekatan utama karena beberapa pertimbangan. *Pertama*, model yang dikembangkan ditujukan sebagai komponen sistem peringatan dini yang membutuhkan keputusan yang konsisten dan dapat ditelusuri kembali. *Threshold* yang berubah-ubah dapat menyulitkan operator dalam memahami alasan munculnya alert tertentu. *Kedua*, distribusi data latih pada periode 2022–2024 relatif stabil, sehingga tidak terdapat urgensi yang kuat untuk menggunakan *threshold* yang adaptif terhadap waktu. *Ketiga*, *static threshold* lebih mudah dipertahankan secara metodologis karena nilai ambangnya tetap dan tidak bergantung pada parameter eksternal yang dapat menimbulkan ambiguitas. Pendekatan *dynamic threshold* dapat dipertimbangkan sebagai arah penelitian lanjutan apabila distribusi data pada periode mendatang menunjukkan pergeseran yang signifikan.

c) *Cost-Sensitive Threshold*

Untuk memperkuat pendekatan *static threshold*, penelitian ini menerapkan *cost-sensitive adjustment* yang mempertimbangkan asimetri biaya kesalahan deteksi. Pada konteks deteksi risiko rantai pasok pertanian, biaya melewati anomali nyata (*false negative*) umumnya lebih besar dibandingkan biaya alarm palsu (*false positive*). Anomali yang tidak terdeteksi berpotensi menyebabkan kerugian operasional yang signifikan, sedangkan alarm palsu hanya menambah beban verifikasi yang relatif terbatas. Oleh karena itu, *threshold* dirancang agar lebih agresif dalam menangkap anomali, dengan trade-off berupa peningkatan jumlah *false positive* yang dapat diterima.

Penyesuaian *cost-sensitive* dilakukan dengan asumsi rasio biaya *false negative* terhadap *false positive* sebesar 5 banding 1. Rasio ini dipilih sebagai asumsi awal yang masuk akal untuk konteks penelitian ini, mengikuti praktik umum pada sistem peringatan dini berbasis pertanian yang menempatkan keandalan deteksi sebagai prioritas utama. Berdasarkan rasio biaya tersebut, *threshold* disesuaikan dari nilai kuantil 0,98 awal ke nilai yang meminimumkan total *expected cost* pada data latih. Penyesuaian ini umumnya menghasilkan *threshold* yang sedikit lebih rendah dibandingkan *threshold* tanpa pertimbangan biaya, sehingga model menjadi lebih sensitif dalam mendeteksi anomali. Sensitivitas terhadap nilai rasio biaya dapat dieksplorasi lebih lanjut sebagai bagian dari analisis tambahan pada Bab 4.

d) Aturan Keputusan dan Pemetaan *Severity*

Setelah *threshold* per domain ditentukan untuk setiap model, keputusan deteksi dilakukan dengan aturan sederhana, yaitu suatu observasi diberi label *is_anomaly* = 1 apabila skor model lebih besar atau sama dengan *threshold* yang berlaku, dan diberi label *is_anomaly* = 0 apabila tidak. Aturan ini diterapkan secara seragam untuk ketiga model (*Isolation Forest*, *Bayesian Network*, dan *hybrid*).

Untuk pemetaan tingkat keparahan, penelitian ini menggunakan pendekatan *post-hoc severity classification*, yaitu *severity* ditentukan setelah keputusan biner dibuat. Bagi observasi dengan *is_anomaly* = 0, *severity* diberi nilai Normal. Bagi observasi dengan *is_anomaly* = 1, *severity* ditentukan berdasarkan magnitude skor model: kategori Waspada diberikan apabila skor berada di antara *threshold* dan kuantil 0,995 dari distribusi skor data latih, sedangkan kategori Bahaya diberikan apabila skor berada pada atau di atas kuantil 0,995. Pendekatan ini menghasilkan tiga kategori *severity* (Normal, Waspada, Bahaya) yang konsisten dengan definisi pada Subbab 3.5.1, sekaligus memberikan informasi kuantitatif tentang tingkat keparahan setiap deteksi. Keluaran akhir dari mekanisme ini berupa keputusan biner anomali, kategori *severity*, dan skor mentah yang menjadi dasar keputusan. Ketiga komponen keluaran tersebut akan digunakan sebagai dasar evaluasi kinerja model pada Subbab 3.5.7, sekaligus menjadi masukan bagi penyusunan tabel *fact alerts* yang menjadi keluaran operasional sistem peringatan dini.

3.5.7. Evaluasi Model

Evaluasi model dilakukan untuk mengukur kinerja deteksi anomali dari ketiga model yang dikembangkan, yaitu *Isolation Forest*, *Bayesian Network*, dan model *hybrid Isolation Forest–Bayesian Network*. Evaluasi dilakukan pada level keluaran model, yaitu skor dan keputusan biner anomali setelah penerapan *threshold* sebagaimana dijelaskan pada Subbab 3.5.6, dengan label biner *label_is_anomaly* yang dibentuk pada Subbab 3.5.1 sebagai acuan kebenaran. Evaluasi dirancang agar memberikan gambaran kinerja yang adil antar model, sekaligus mendukung perbandingan langsung antara model tunggal dan model *hybrid*.

a) Skema Pembagian Data

Pembagian data dilakukan secara berbasis waktu (*time-based split*) untuk mempertahankan struktur temporal data dan menghindari kebocoran informasi dari masa depan ke masa lalu pada saat pelatihan. Data periode 1 Januari 2022 hingga 30 Juni 2024 (sekitar 130 minggu) digunakan sebagai data latih, sedangkan data periode 1 Juli 2024 hingga 31 Desember 2024 (sekitar 26 minggu) digunakan sebagai data uji. Pembagian ini diterapkan secara konsisten untuk seluruh model dan seluruh domain risiko.

Pendekatan *time-based split* dipilih karena lebih sesuai dengan karakteristik penelitian deteksi risiko yang akan diterapkan pada data baru di masa depan. Pendekatan ini memastikan bahwa proses pelatihan model dilakukan tanpa pengetahuan tentang data uji, sehingga estimasi kinerja yang dihasilkan lebih mencerminkan kemampuan model dalam menghadapi data yang belum pernah dilihat sebelumnya.

b) *Confusion Matrix* dan *Metrik* Klasifikasi

Evaluasi kinerja klasifikasi dilakukan menggunakan *confusion matrix* sebagai dasar perhitungan metrik. *Confusion matrix* memberikan gambaran rinci tentang jumlah keputusan benar dan salah yang dibuat model, terbagi ke dalam empat kategori:

- (1) *True positive* (TP), yaitu observasi anomali yang berhasil terdeteksi oleh model.
- (2) *True negative* (TN), yaitu observasi normal yang dikenali sebagai normal oleh model.

- (3) *False positive* (FP), yaitu observasi normal yang salah dideteksi sebagai anomali.
- (4) *False negative* (FN), yaitu observasi anomali yang tidak terdeteksi oleh model.

Berdasarkan keempat kategori tersebut, dihitung tiga metrik klasifikasi utama:

- (1) *Precision*, yaitu proporsi observasi yang dideteksi sebagai anomali dan benar-benar merupakan anomali. *Precision* mengukur ketepatan deteksi, di mana nilai yang lebih tinggi menunjukkan model jarang menghasilkan alarm palsu.
- (2) *Recall*, yaitu proporsi observasi anomali yang berhasil dideteksi dari seluruh anomali yang ada. *Recall* mengukur kelengkapan deteksi, di mana nilai yang lebih tinggi menunjukkan model jarang melewatkan anomali nyata.
- (3) *F1-score*, yaitu rata-rata harmonis dari *precision* dan *recall* yang memberikan ukuran keseimbangan antara ketepatan dan kelengkapan deteksi

c) *Receiver Operating Characteristic* dan *Area Under Curve*

Selain metrik klasifikasi pada satu titik *threshold*, evaluasi juga dilakukan menggunakan *Receiver Operating Characteristic* (ROC) dan *Area Under Curve* (AUC). Kurva ROC menggambarkan hubungan antara *true positive rate* dan *false positive rate* pada berbagai nilai *threshold*, sedangkan AUC merangkum kurva tersebut menjadi satu nilai numerik antara 0 dan 1. Nilai AUC yang lebih tinggi menunjukkan kemampuan model yang lebih baik dalam membedakan observasi anomali dan normal pada berbagai *threshold*, terlepas dari nilai *threshold* spesifik yang digunakan.

ROC dan AUC dipilih karena memberikan gambaran kinerja model yang lebih komprehensif dibandingkan metrik klasifikasi pada satu *threshold*. Dengan demikian, evaluasi tidak hanya bergantung pada keputusan deteksi pada nilai *threshold* yang dipilih, melainkan juga pada kemampuan model membedakan kelas pada keseluruhan rentang skor. Hal ini penting untuk membandingkan ketiga model secara adil, terutama ketika *threshold* yang digunakan dapat berbeda antar model.

d) Perbandingan *Isolation Forest*, *Bayesian Network*, dan *Hybrid*

Perbandingan kinerja antar model dilakukan untuk mengukur sejauh mana integrasi pendekatan *Isolation Forest* dan *Bayesian Network* melalui *feature-level fusion* memberikan peningkatan dibandingkan penggunaan model tunggal. Perbandingan dilakukan menggunakan kelima metrik di atas, yaitu *confusion matrix*, *precision*, *recall*, *F1-score*, dan AUC, pada dua tingkat analisis :

- (1) Tingkat global, yaitu kinerja keseluruhan ketiga model pada gabungan seluruh domain risiko. Perbandingan global memberikan gambaran umum tentang model mana yang memiliki kinerja terbaik secara menyeluruh.
- (2) Tingkat per-domain, yaitu kinerja ketiga model pada setiap domain risiko (harga, cuaca, OPT, distribusi, tindakan pengelolaan, dan produksi) secara terpisah. Perbandingan per-domain memungkinkan identifikasi domain mana yang paling diuntungkan dari pendekatan *hybrid*, dan domain mana yang menunjukkan perbedaan kinerja yang lebih kecil antar model.

3.5.8. Kalibrasi, Uncertainty, dan Explainability Model

Selain evaluasi kinerja klasifikasi pada Subbab 3.5.7, penelitian ini juga menerapkan tiga aspek evaluasi tambahan yang relevan untuk model yang akan digunakan sebagai komponen sistem peringatan dini, yaitu kalibrasi probabilistik, *uncertainty propagation*, dan *explainability*. Ketiga aspek ini ditujukan untuk meningkatkan kepercayaan terhadap keluaran model, sehingga probabilitas yang dihasilkan tidak hanya dapat diukur kinerjanya secara numerik, tetapi juga dapat ditafsirkan dan dipertanggungjawabkan pada tingkat keputusan operasional.

a) Kalibrasi *Probabilistik* dengan *Brier Score*

Kalibrasi probabilistik dilakukan untuk mengukur seberapa baik probabilitas yang dihasilkan model sesuai dengan frekuensi kejadian sebenarnya. Model dikatakan terkalibrasi dengan baik apabila probabilitas yang dihasilkan dapat dipercaya secara langsung; misalnya, observasi yang mendapat probabilitas anomali sebesar 0,80 sebaiknya benar-benar tergolong anomali pada sekitar 80% kasus secara historis. Kalibrasi penting untuk model yang akan digunakan secara operasional, karena operator sistem peringatan dini perlu membandingkan tingkat keyakinan model dengan keputusan tindakan yang akan diambil.

Penelitian ini menggunakan *Brier score* sebagai metrik kalibrasi utama. *Brier score* mengukur rata-rata kuadrat selisih antara probabilitas prediksi dan label aktual, dengan nilai yang lebih rendah menunjukkan kalibrasi yang lebih baik. Metrik ini dipilih karena memberikan satu nilai numerik yang merangkum kualitas kalibrasi keseluruhan dan mudah dibandingkan antar model. *Brier score* dihitung untuk ketiga model (*Isolation Forest*, *Bayesian Network*, dan *hybrid*), dan menjadi indikator pelengkap di samping metrik klasifikasi pada Subbab 3.5.7.

b) *Uncertainty Propagation*

Uncertainty propagation dilakukan untuk mengukur tingkat ketidakpastian model terhadap setiap keputusan yang dihasilkan. Pada konteks deteksi anomali, ketidakpastian penting untuk dipahami karena observasi yang mendekati ambang keputusan (*threshold*) cenderung memiliki tingkat keyakinan yang lebih rendah dibandingkan observasi dengan skor sangat tinggi atau sangat rendah. Informasi ketidakpastian membantu operator membedakan deteksi yang berasal dari pola yang sangat jelas dan deteksi yang berada di area abu-abu. Penelitian ini menggunakan pendekatan *uncertainty propagation* berbasis *Bayesian inference* langsung dari distribusi *posterior* model *Bayesian Network*, baik pada model tunggal maupun pada model *hybrid*. Pendekatan ini dipilih karena beberapa alasan:

- (1) Konsistensi dengan model, model *Bayesian Network* secara natural menghasilkan distribusi probabilitas penuh, sehingga ketidakpastian dapat diturunkan langsung tanpa transformasi tambahan.
- (2) Efisiensi komputasi, pendekatan ini tidak memerlukan pelatihan ulang model dengan resampling data atau metode *bootstrap*, sehingga lebih ringan secara komputasi.
- (3) Interpretasi yang langsung, ukuran ketidakpastian yang dihasilkan, seperti rentang probabilitas atau entropi distribusi *posterior*, memiliki interpretasi probabilistik yang jelas dan dapat dilaporkan bersama keputusan deteksi.

c) *Explainability* dengan *BN Reasoning*

Explainability dilakukan untuk memberikan penjelasan terhadap keputusan deteksi yang dihasilkan model, sehingga setiap alert yang muncul dapat ditelusuri kontribusi penyebabnya. Pada sistem peringatan dini, *explainability* sangat penting karena keputusan tindakan operasional sering memerlukan justifikasi yang dapat dipahami oleh pemangku kepentingan, bukan sekadar nilai probabilitas tanpa konteks. Penelitian ini menggunakan pendekatan *Bayesian Network reasoning* sebagai metode *explainability*, yaitu memanfaatkan struktur DAG dan *Conditional Probability Table* (CPT) yang sudah diestimasi pada Subbab 3.5.4 dan 3.5.5 untuk menjelaskan keputusan model. Pendekatan ini dipilih karena beberapa pertimbangan:

- (1) Memanfaatkan struktur model yang sudah ada, tidak diperlukan kerangka kerja eksternal seperti *SHAP*, karena struktur probabilistik *Bayesian Network* secara natural mendukung penalaran kausal.
- (2) Konsisten dengan kerangka inferensi, penjelasan yang dihasilkan menggunakan logika probabilistik yang sama dengan logika pembuatan keputusan, sehingga interpretasi tetap koheren.
- (3) Sesuai dengan kebutuhan pemangku kepentingan: penjelasan dalam bentuk kontribusi probabilistik per fitur (misalnya, fitur mana yang paling memengaruhi probabilitas anomali pada observasi tertentu) lebih mudah dipahami oleh operator dibandingkan kontribusi numerik abstrak.

d) Integrasi pada Keluaran Model


Ketiga aspek evaluasi tambahan di atas tidak hanya menjadi bagian dari analisis evaluasi pada Bab 4, tetapi juga diintegrasikan ke dalam keluaran model sebagai komponen pelengkap. Setiap deteksi yang dihasilkan model akan dilengkapi dengan tingkat ketidakpastian dari *uncertainty propagation* dan penjelasan kontribusi fitur dari *Bayesian Network reasoning*. *Brier score* sebagai indikator kalibrasi dilaporkan pada level keseluruhan model dan per-domain, sehingga kepercayaan terhadap probabilitas yang dihasilkan dapat diestimasi secara terukur.

Dengan kombinasi evaluasi pada Subbab 3.5.7 dan ketiga aspek evaluasi tambahan pada subbab ini, model yang dikembangkan diharapkan tidak hanya menunjukkan kinerja klasifikasi yang baik, tetapi juga memenuhi kebutuhan

transparansi dan kepercayaan yang diperlukan untuk implementasi sebagai komponen sistem peringatan dini pada rantai pasok pertanian.

3.6. Alur Penelitian

Alur penelitian disusun untuk menggambarkan tahapan utama pelaksanaan penelitian mulai dari identifikasi masalah hingga penarikan kesimpulan. Alur ini menunjukkan bahwa penelitian dilakukan melalui pengumpulan data sekunder, pengolahan data multi-domain, pembentukan fitur dan label risiko, pengembangan model deteksi risiko, serta evaluasi perbandingan performa model. Alur penelitian ditunjukkan pada Gambar 3.3.



Gambar 3.3 Alur Penelitian

Berdasarkan Gambar 3.3, tahapan penelitian ini adalah sebagai berikut:

a) Identifikasi masalah dan studi literatur

Tahap ini dilakukan untuk mengidentifikasi permasalahan risiko multi-domain pada rantai pasok pertanian serta memahami keterbatasan pendekatan model tunggal. Studi literatur digunakan untuk meninjau teori dan penelitian terdahulu yang relevan dengan anomaly detection, Isolation Forest, Bayesian Network, model hybrid, dan deteksi risiko pertanian.

b) Perumusan masalah, tujuan, dan batasan penelitian

Tahap ini menetapkan rumusan masalah, tujuan penelitian, serta batasan ruang lingkup agar penelitian tetap terarah. Fokus penelitian diarahkan pada pengembangan dan evaluasi model hybrid Isolation Forest–Bayesian Network untuk deteksi risiko multi-domain.

c) Penetapan objek penelitian dan unit analisis

Tahap ini menetapkan objek penelitian berupa deteksi risiko pada rantai pasok pertanian. Unit analisis yang digunakan adalah observasi mingguan pada level kecamatan agar data dari berbagai domain dapat dianalisis dalam struktur yang seragam.

d) Pengumpulan data sekunder

Tahap ini dilakukan dengan mengumpulkan data historis periode 2022–2024 dari sumber resmi. Data cuaca diperoleh dari BMKG, sedangkan data harga, OPT, distribusi, tindakan pengelolaan, dan produksi diperoleh dari Dinas Pertanian Kabupaten Sumedang.

e) Pengolahan data multi-domain

Data yang telah dikumpulkan dikelompokkan ke dalam enam domain risiko, yaitu harga, cuaca, organisme pengganggu tanaman, distribusi, tindakan pengelolaan, dan produksi. Pengelompokan ini dilakukan agar karakteristik masing-masing domain tetap dapat dianalisis secara terpisah.

f) Validasi data dan preprocessing

Tahap ini mencakup pemeriksaan kelayakan data, pembersihan data, penanganan nilai hilang, normalisasi, dan penyesuaian format data. Proses ini dilakukan agar data siap digunakan pada tahap pembentukan fitur dan pemodelan.

g) Temporal alignment dan feature engineering

Tahap ini menyelaraskan data dari berbagai resolusi waktu ke dalam unit analisis mingguan. Setelah itu, dilakukan pembentukan fitur-fitur turunan seperti fitur dasar, fitur temporal, dan fitur lintas-domain sesuai kebutuhan pemodelan.

h) Pembentukan label risiko

Tahap ini dilakukan untuk menghasilkan label risiko yang digunakan sebagai dasar pelatihan dan evaluasi model. Label risiko dibentuk dalam bentuk label anomali dan tingkat keparahan risiko.

i) Pengembangan model deteksi risiko

Tahap ini mencakup pengembangan tiga model, yaitu Isolation Forest, Bayesian Network, dan model hybrid Isolation Forest–Bayesian Network. Isolation Forest digunakan untuk menghasilkan skor anomali, Bayesian Network digunakan untuk menghasilkan probabilitas risiko, sedangkan model hybrid mengintegrasikan keduanya.

j) Thresholding dan keputusan deteksi

Tahap ini mengubah keluaran model menjadi keputusan deteksi berupa kondisi normal atau anomali. Penentuan keputusan dilakukan menggunakan threshold yang ditetapkan sesuai karakteristik masing-masing domain.

k) Evaluasi dan perbandingan model

Tahap ini dilakukan untuk menilai dan membandingkan performa Isolation Forest, Bayesian Network, dan model hybrid. Evaluasi dilakukan menggunakan metrik yang telah ditentukan, seperti precision, recall, F1-score, dan ROC-AUC.

l) Analisis hasil

Tahap ini dilakukan untuk menginterpretasikan hasil evaluasi model dan membandingkan karakteristik performa masing-masing pendekatan. Analisis ini digunakan untuk menilai apakah model hybrid memberikan hasil yang lebih baik dibandingkan model tunggal.

m) Kesimpulan penelitian

Tahap terakhir adalah merumuskan kesimpulan berdasarkan hasil evaluasi dan analisis. Kesimpulan disusun untuk menjawab rumusan masalah serta menunjukkan kontribusi model hybrid dalam deteksi risiko multi-domain pada rantai pasok pertanian.

3.7. Jadwal Penelitian

Penelitian ini dilaksanakan dalam rentang waktu dari bulan Februari hingga Juli 2026. Kegiatan penelitian disusun secara bertahap mulai dari penyusunan proposal hingga sidang skripsi. Rincian jadwal pelaksanaan kegiatan penelitian dapat dilihat pada tabel berikut.

Tabel 3.3 Jadwal Penelitian

No	Kegiatan Penelitian	Fase	Feb	Mar	Apr	Mei	Jun	Jul
1	Studi pustaka dan telaah literatur	Fase Persiapan	✓	✓				
2	Penyusunan proposal (Bab 1, 2, 3)	Fase Persiapan	✓	✓	✓			
3	Seminar proposal	Fase Persiapan			✓			
4	Pengumpulan dan validasi data	Fase Persiapan		✓	✓			
5	Pengolahan data dan pembentukan label	Fase Implementasi			✓	✓		
6	Pengembangan model	Fase Implementasi				✓		
7	Evaluasi model	Fase Implementasi					✓	✓
8	Penyusunan laporan akhir	Fase Implementasi					✓	✓
9	Sidang akhir	Fase Implementasi						✓

DAFTAR PUSTAKA

- [1] Y. Xue, J. Yan, M. Mohsin, and A. Mehak, "Supply chain risks in agri-food systems: a comprehensive review of economic vulnerabilities and mitigation approaches," *Front. Sustain. Food Syst.*, vol. 9, p. 1649834, Nov. 2025, doi: 10.3389/fsufs.2025.1649834.
- [2] Y. Zolotnytska *et al.*, "Drivers of Global Wheat and Corn Price Dynamics: Implications for Sustainable Food Systems," *Sustainability* 2025, Vol. 17, Page 8581, vol. 17, no. 19, p. 8581, Sep. 2025, doi: 10.3390/su17198581.
- [3] J. Burney, C. McIntosh, B. Lopez-Videla, K. Samphantharak, and A. G. Maia, "Empirical modeling of agricultural climate risk," *Proc. Natl. Acad. Sci. U. S. A.*, vol. 121, no. 16, p. e2215677121, Apr. 2024, doi: 10.1073/pnas.2215677121.
- [4] H. C. Han and D. C. Huang, "Graph-Theoretic Detection of Anomalies in Supply Chains: A PoR-Based Approach Using Laplacian Flow and Sheaf Theory," *Mathematics* 2025, vol. 13, no. 11, May 2025, doi: 10.3390/math13111795.
- [5] Z. Xie, H. Long, C. Ling, Y. Zhou, and Y. Luo, "An anomaly detection scheme for data stream in cold chain logistics," *PLoS One*, vol. 20, no. 3, p. e0315322, Mar. 2025, doi: 10.1371/journal.pone.0315322.
- [6] E. Sediyo, K. D. Hartomo, C. Arthur, I. Utami, R. Prabowo, and R. Chiong, "An integrated framework for multi-commodity agricultural price forecasting and anomaly detection using attention-boosted models," *J. Agric. Food Res.*, vol. 22, p. 102021, Aug. 2025, doi: 10.1016/j.jafr.2025.102021.
- [7] C. Wei, Y. Shan, and M. Z. Zhen, "Deep learning-based anomaly detection for precision field crop protection," *Front. Plant Sci.*, vol. 16, p. 1576756, May 2025, doi: 10.3389/fpls.2025.1576756.
- [8] T. J. Krupnik *et al.*, "A weather-forecast driven early warning system for wheat blast disease: User-centered design, validation, and scaling in Bangladesh and Brazil," *Clim. Serv.*, vol. 39, no. 12, p. 100589, Aug. 2025, doi: 10.1016/j.cliser.2025.100589.
- [9] R. Abi, "Bayesian Network Modeling for Probabilistic Reasoning and Risk Assessment in Large-Scale Industrial Datasets," *International Journal of Science and Research Archive*, vol. 15, no. 3, pp. 587–607, Jun. 2025, doi: 10.30574/ijrsra.2025.15.3.1765.
- [10] K. Stenhouse *et al.*, "A simulated annealing-based Bayesian network structure optimization framework for late morbidity prediction with a large prospective dataset," *Med. Phys.*, vol. 52, no. 6, pp. 5051–5063, Jun. 2025, doi: 10.1002/mp.17881.

- [11] A. Afandi, H. Bedi Agtriadi, and M. Nur Indah Susanti, “Advanced Credit Scoring with Naive Bayes Algorithm: Improving Accuracy and Reliability in Financial Risk Assessment,” *Jurnal E-Komtek (Elektro-Komputer-Teknik)*, vol. 8, no. 2, pp. 399–409, Dec. 2024, doi: 10.37339/e-komtek.v8i2.2160.
- [12] Q. A. Wang, A. W. Lu, Y. Q. Ni, J. F. Wang, and Z. G. Ma, “Bayesian Network in Structural Health Monitoring: Theoretical Background and Applications Review,” *Sensors* 2025, Vol. 25, Page 3577, vol. 25, no. 12, p. 3577, Jun. 2025, doi: 10.3390/s25123577.
- [13] N. Babakov, A. Sivaprasad, E. Reiter, and A. Bugarín-Diz, “Reusability of Bayesian Networks case studies: a survey,” *Applied Intelligence* 2025 55:6, vol. 55, no. 6, pp. 417–, Feb. 2025, doi: 10.1007/s10489-025-06289-5.
- [14] M. Shanaa and S. Abdallah, “A Hybrid Anomaly Detection Framework Combining Supervised and Unsupervised Learning for Credit Card Fraud Detection,” *F1000Research* 2025 14:664, vol. 14, p. 664, Jul. 2025, doi: 10.12688/f1000research.166350.1.
- [15] L. Wang, S. Zhou, T. Zhang, C. Guo, and X. Huang, “An Unsupervised Anomaly Detection Method for Nuclear Reactor Coolant Pumps Based on Kernel Self-Organizing Map and Bayesian Posterior Inference,” *Energies* 2025, Vol. 18, Page 2887, vol. 18, no. 11, p. 2887, May 2025, doi: 10.3390/en18112887.
- [16] M. M. Aslam, A. Tufail, L. C. De Silva, and R. A. A. H. M. Apong, “Multi-Feature Hybrid Anomaly Detection in ICS: An Integration of ML, DL, and Statistical Techniques,” *ACM SecTL 2025 - Proceedings of the 3rd ACM Workshop on Secure and Trustworthy Deep Learning Systems, Part of ACM AsiaCCS* 2025, vol. 25, pp. 43–51, Aug. 2025, doi: 10.1145/3709021.3737669.
- [17] M. Sri Lakshmi, G. Rajavikram, V. Dattatreya, B. Swarna Jyothi, S. Patil, and M. Bhavsingh, “Evaluating the Isolation Forest Method for Anomaly Detection in Software-Defined Networking Security,” *Journal of Electrical Systems*, vol. 19, no. 4, pp. 279–297, 2023, doi: 10.52783/jes.639.
- [18] V. Claudia *et al.*, “ISOLATION FOREST PARAMETER TUNING FOR MOBILE APP ANOMALY DETECTION BASED ON PERMISSION REQUESTS,” *Jurnal Pilar Nusa Mandiri*, vol. 21, no. 2, pp. 187–197, Sep. 2025, doi: 10.33480/pilar.v21i2.6647.
- [19] V. Yepmo, G. Smits, M. J. Lesot, and O. Pivert, “CADI: Contextual Anomaly Detection using an Isolation-Forest,” *Proceedings of the ACM Symposium on Applied Computing*, pp. 935–944, Apr. 2024, doi: 10.1145/3605098.3635969.
- [20] H. Choi and K. Jung, “Impact of Data Distribution and Bootstrap Setting on Anomaly Detection Using Isolation Forest in Process Quality Control,”

Entropy 2025, Vol. 27, Page 761, vol. 27, no. 7, p. 761, Jul. 2025, doi: 10.3390/e27070761.

- [21] A. Entezami, H. Sarmadi, B. Behkamal, and S. Mariani, “Early warning of structural damage via manifold learning-aided data clustering and non-parametric probabilistic anomaly detection,” *Mech. Syst. Signal Process.*, vol. 224, no. 3, p. 111984, Feb. 2025, doi: 10.1016/j.ymssp.2024.111984.
- [22] J. Werner *et al.*, “Enhanced Anomaly Detection for Capsule Endoscopy Using Ensemble Learning Strategies,” *Annu. Int. Conf. IEEE Eng. Med. Biol. Soc.*, vol. 2025, pp. 1–7, Jul. 2025, doi: 10.1109/EMBC58623.2025.11253055.
- [23] S. Das, S. Shukla, A. S. Kailasam, A. Rai, and A. Chakraborti, “Predicting and Mitigating Agricultural Price Volatility Using Climate Scenarios and Risk Models,” Mar. 2025, Accessed: Mar. 08, 2026. [Online]. Available: <http://arxiv.org/abs/2503.24324>
- [24] K. Wichianrat, P. Chamchang, and Y. Fan, “Risk Identification and Assessment in Cold Chain Logistics for Durian Exports from Thailand to China: Insights from Packing House Perspectives,” *ABAC Journal*, vol. 45, no. 3, pp. 182–199, Jul. 2025, doi: 10.59865/abacj.2025.22.
- [25] R. Shyam, K. Lakra, A. Kumar, and G. Dwivedi, “AI-powered early warning system for agricultural risk mitigation based on predictive inference from environmental stress factors and disease propagation models,” *International Journal of Agriculture and Food Science*, vol. 7, no. 9, pp. 29–35, Jan. 2025, doi: 10.33545/2664844x.2025.v7.i9a.728.
- [26] X. Li *et al.*, “Smart Grain Storage Solution: Integrated Deep Learning Framework for Grain Storage Monitoring and Risk Alert,” *Foods* 2025, Vol. 14, Page 1024, vol. 14, no. 6, p. 1024, Mar. 2025, doi: 10.3390/foods14061024.
- [27] D. P. Edelson *et al.*, “Early Warning Scores With and Without Artificial Intelligence,” *JAMA Netw. Open*, vol. 7, no. 10, pp. e2438986–e2438986, Oct. 2024, doi: 10.1001/jamanetworkopen.2024.38986.
- [28] T. Sim *et al.*, “Prospective external validation of a deep-learning-based early-warning system for major adverse events in general wards in South Korea,” *Acute and Critical Care*, vol. 40, no. 2, pp. 197–208, May 2025, doi: 10.4266/acc.000525.
- [29] D. M. Townsend, R. A. Hunt, and J. Rady, “Chance, probability, and uncertainty at the edge of human reasoning: What is Knightian uncertainty?,” *Strategic Entrepreneurship Journal*, vol. 18, no. 3, pp. 451–474, Sep. 2024, doi: 10.1002/sej.1516.
- [30] A. E. Ebadollahi and S. R. Rahman, “Time-dependent uncertainty quantification analysis of complex dynamical systems,” *14th International*

Conference on Structural Safety and Reliability - ICOSSAR '25, May 2025, doi: 10.23967/icossar.2025.005.

- [31] S. Kumari, C. Prabha, A. Karim, M. M. Hassan, and S. Azam, "A Comprehensive Investigation of Anomaly Detection Methods in Deep Learning and Machine Learning: 2019–2023," *IET Inf. Secur.*, vol. 2024, no. 1, p. 8821891, Jan. 2024, doi: 10.1049/2024/8821891.
- [32] N. Mejri, L. Lopez-Fuentes, K. Roy, P. Chernakov, E. Ghorbel, and D. Aouada, "Unsupervised anomaly detection in time-series: An extensive evaluation and analysis of state-of-the-art methods," *Expert Syst. Appl.*, vol. 256, pp. 957–4174, Dec. 2024, doi: 10.1016/j.eswa.2024.124922.
- [33] Y. Cao, H. Xiang, H. Zhang, Y. Zhu, and K. M. Ting, "Anomaly Detection Based on Isolation Mechanisms: A Survey," *Machine Intelligence Research* 2025 22:5, vol. 22, no. 5, pp. 849–865, Sep. 2025, doi: 10.1007/s11633-025-1554-4.
- [34] B. Pelletier, "On the statistical properties of the isolation forest anomaly detection method," <https://doi.org/10.1214/24-EJS2305>, vol. 18, no. 2, pp. 4322–4381, Jan. 2024, doi: 10.1214/24-EJS2305.
- [35] C. Wei, T. Zhang, C. Li, P. Wang, and Z. Ye, "TAN-FGBMLE: Tree-Augmented Naïve Bayes Structure Learning Based on Fast Generative Bootstrap Maximum Likelihood Estimation for Continuous-Variable Classification," *Entropy* 2025, Vol. 27, Page 1216, vol. 27, no. 12, p. 1216, Nov. 2025, doi: 10.3390/e27121216.
- [36] F. R. Dastjerdi and L. Cai, "Augmenting Naïve Bayes Classifiers with k-Tree Topology," *Mathematics* 2025, Vol. 13, Page 2185, vol. 13, no. 13, p. 2185, Jul. 2025, doi: 10.3390/math13132185.
- [37] E. Richardson, R. Trevizani, J. A. Greenbaum, H. Carter, M. Nielsen, and B. Peters, "The receiver operating characteristic curve accurately assesses imbalanced datasets," *Patterns*, vol. 5, no. 6, p. 100994, Jun. 2024, doi: 10.1016/j.patter.2024.100994.
- [38] W. Chen, K. Yang, Z. Yu, Y. Shi, and C. L. P. Chen, "A survey on imbalanced learning: latest research, applications and future directions," *Artif. Intell. Rev.*, vol. 57, no. 6, pp. 137–, Jun. 2024, doi: 10.1007/s10462-024-10759-6.
- [39] V. Komisarenko and M. Kull, "Cost-sensitive classification with cost uncertainty: do we need surrogate losses?," *Machine Learning* 2025 114:6, vol. 114, no. 6, pp. 132–, Apr. 2025, doi: 10.1007/s10994-024-06634-8.